Aprendizaje por Refuerzo

Grado en Ingeniería Matemática e Inteligencia Artificial (IMAT) – 4º A
Universidad Pontificia Comillas, ICAI

Práctica 2:
RL tabular sin modelo: SARSA y Q-learning

Informe de laboratorio

Jorge Carnicero
Jorge González
Andrés Gil

Índice

1. Introducción y metodología **1**

2. Trabajo previo: valores óptimos q_* **2**

3. SARSA **4**
3.1. Fundamentos e implementación 4
3.2. Convergencia en s_6 y s_{13} 4
3.3. Influencia de los hiperparámetros 5

4. Q-learning **8**
4.1. Fundamentos 8
4.2. Convergencia en s_6 y s_{13} 8
4.3. Influencia de los hiperparámetros 9

5. Comparación entre SARSA y Q-learning **10**

6. Conclusiones **14**

7. Uso de la IA **14**

1. Introducción y metodología

En la Práctica 1 resolvimos *Jump To The Goal* con programación dinámica, usando el modelo $p(s', r \mid s, a)$. Ahora el agente no lo conoce: aprende solo de las transiciones $(S_t, A_t, R_{t+1}, S_{t+1})$ que genera. Implementamos los dos métodos de diferencias temporales (TD) tabulares, SARSA y Q-learning, y analizamos qué estiman, cuánta experiencia necesitan y por qué difieren.

Configuración base. Entorno determinista, $\gamma = 0.9$, $r_s = -1$, $r_{obs} = -5$, $r_{goal} = +5$, $\varepsilon = 0.2$, $\alpha = 0.1$ y $Q_0 = 0$ (valores por defecto de `main.py`), 20 000 episodios ($\approx$ 80 000 pasos) y estado inicial uniforme en $s_{init} = \{s_0, s_4, s_8, s_{12}\}$.

Metodología. Hemos validado el código mediante las 32 comprobaciones automáticas de `validate_algorithms.py` (actualizaciones, terminales y desempates). Para comparar los algoritmos hemos variado α, ε, Q_0 y algunas combinaciones, además de probar exploración decreciente. Así estudiamos su efecto sobre la rapidez de aprendizaje, el retorno y los valores Q. Hemos utilizado un ejecutor que llama a las funciones originales, reproduce `main.py` y registra Q, visitas $N(s, a)$, retornos y evaluaciones greedy ($\varepsilon = 0$) cada 20 episodios desde los cuatro estados iniciales. Repetimos cada configuración con 10 semillas (20 en la base), las mismas para ambos algoritmos, y presentamos medias, percentiles e intervalos bootstrap al 95 %. Calculamos las referencias teóricas con el modelo P, sin proporcionárselo a los agentes. En total, hemos realizado 400 entrenamientos.

Distinguimos *pasos* (transiciones globales), *episodios* y *visitas* a un par. El *retorno* es la suma sin descuento de un episodio, como lo registra `entrenamiento.py`. Los resultados de eficiencia se refieren a este entorno determinista y a las configuraciones ensayadas; las pruebas estadísticas constituyen evidencia experimental, no garantías universales.

Reproducción (desde `lab2/experiments`)

```
python validate_algorithms.py
python run_experiments.py
python analyze_results.py
```

2. Trabajo previo: valores óptimos q_*

Con el modelo determinista, q_* cumple la ecuación de optimalidad de Bellman

$$q_*(s,a) = r(s,a) + \gamma \max_{a'} q_*(s',a'), \qquad q_*(T,\cdot) = 0. \tag{1}$$

El agente siempre avanza una columna (o cae una fila en la última), así que el grafo de transiciones es acíclico y q_* se obtiene hacia atrás: $q_*(s_7,\cdot) = 5$, $q_*(s_3,\cdot) = -1 + 0.9 \cdot 5 = 3.5$, $q_*(s_6,\nearrow) = -1 + 0.9 \cdot 3.5 = 2.15$, $q_*(s_{13},\nearrow) = -1 + 0.9\, q_*(s_{11},\nearrow) = 2.15$ y $q_*(s_{13},\searrow) = -1 + 0.9 \max_a q_*(s_{18},a) = -5.5$. La Tabla 1 recoge los 40 valores, que coinciden con $v_* = \max_a q_*$ de Policy y Value Iteration de la Práctica 1 en los 21 estados.

Estado	$q_*(s,\nearrow)$	$q_*(s,\searrow)$	$\mathcal{A}_*(s)$	Observación
s_0	−5.0000	0.9350	$\searrow$	
s_1	−5.0000	−5.0000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición
s_2	−5.0000	3.5000	$\searrow$	inalcanzable
s_3	3.5000	3.5000	$\nearrow, \searrow$	misma transición
s_4	−5.5000	−0.1585	$\searrow$	
s_5	−5.0000	2.1500	$\searrow$	
s_6	2.1500	5.0000	$\searrow$	
s_7	5.0000	5.0000	$\nearrow, \searrow$	misma transición
s_8	0.9350	−5.0000	$\nearrow$	
s_9	−5.0000	0.9350	$\searrow$	
s_{10}	3.5000	3.5000	$\nearrow, \searrow$	empate, rutas distintas
s_{11}	3.5000	−5.9500	$\nearrow$	
s_{12}	−0.1585	−5.0000	$\nearrow$	
s_{13}	2.1500	−5.5000	$\nearrow$	
s_{14}	5.0000	−5.5000	$\nearrow$	
s_{15}	−5.5000	−5.5000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición
s_{16}	−5.0000	−5.0000	$\nearrow, \searrow$	inalcanzable, sin ruta al objetivo, misma transición
s_{17}	3.5000	−5.0000	$\nearrow$	inalcanzable
s_{18}	−5.9500	−5.0000	$\searrow$	sin ruta al objetivo
s_{19}	−5.0000	−5.0000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición

Tabla 1: Valores óptimos $q_*(s,a)$ ($\gamma = 0.9$, $r_s = -1$, $r_{obs} = -5$, $r_{goal} = +5$) y acciones óptimas $\mathcal{A}_*(s)$.

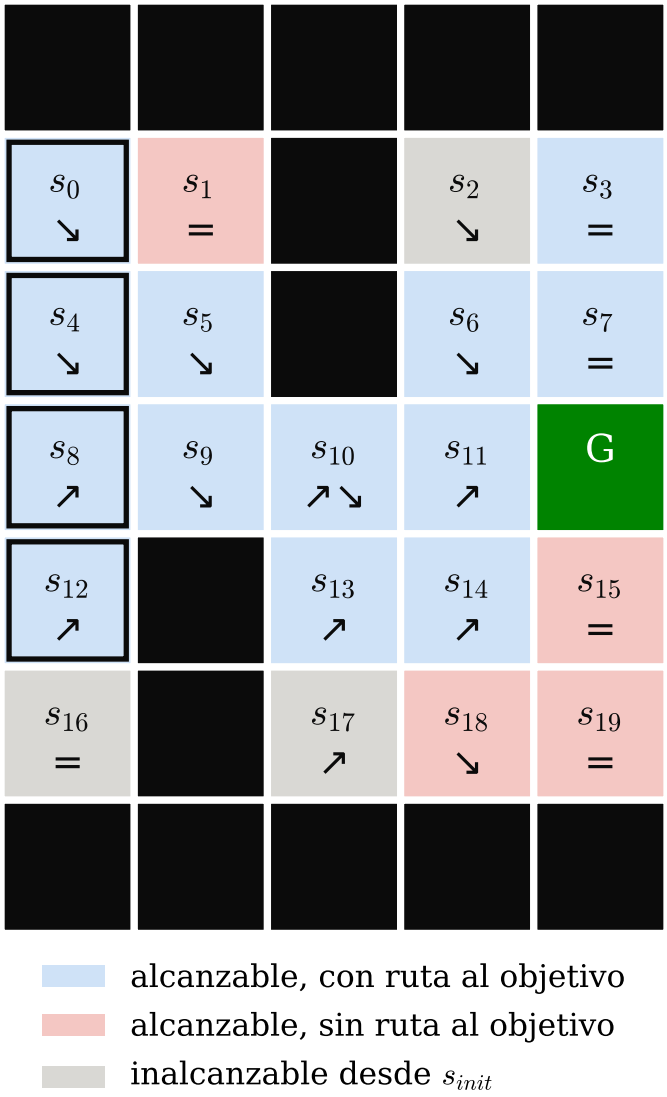


Figura 1: Estructura del entorno: acción óptima (=: ambas acciones producen la misma transición) y estados iniciales (recuadro).

Del modelo extraemos cuatro propiedades que condicionan el aprendizaje (Figura 1):

- **Inalcanzables:** s_2 y s_{17} únicamente tienen obstáculos como posibles predecesores, mientras que s_{16}, situado en la primera columna, no tiene predecesores y tampoco pertenece a s_{init}. Un método sin modelo no puede aprender sus Q, que se quedarán en Q_0. No es un fallo del algoritmo: su convergencia exige visitar cada par.
- **Sin ruta al objetivo:** desde s_1, s_{15}, s_{18} y s_{19} solo se puede chocar; lo óptimo es minimizar la pérdida (s_{18} choca ya, -5, en lugar de $s_{18} \to s_{15} \to s_{19} \to T$, -5.95).
- **Empates:** en s_1, s_3, s_7, s_{15} y s_{19} ambas acciones producen la misma transición; en s_{10}, en cambio, dos rutas distintas (s_6 y s_{14}) valen 3.5.
- **Riesgo exploratorio:** q_* supone que después se actuará de forma óptima. Un error desde s_{14} lleva a un choque seguro ($q_*(s_{14}, \searrow) = -5.5$), mientras que desde s_6 solo alarga el camino ($q_*(s_6, \nearrow) = 2.15$). Esta asimetría explicará la principal diferencia entre los algoritmos.

3. SARSA

3.1. Fundamentos e implementación

SARSA es un método TD(0) de control: tras cada transición actualiza

$$Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma Q(S',A') - Q(S,A)\big], \tag{2}$$

donde A' es la acción que se ejecutará realmente en S', elegida con la misma política ε-greedy (*on-policy*). Si S' es terminal el target es solo R. El target sustituye el retorno completo por una estimación (*bootstrapping*), por lo que el $+5$ se propaga hacia atrás un estado por visita.

```
if terminated:
    Q[state, action] += alpha * (reward - Q[state, action])
else:
    next_action = epsilon_greedy(Q, next_state, epsilon, rng)
    Q[state, action] += alpha * (
        reward + gamma * Q[next_state, next_action] - Q[state, action]
    )
```

Qué estima. Con transiciones deterministas, el valor esperado del target dado Q es

$$(T_\varepsilon Q)(s,a) = r + \gamma\Big[(1-\varepsilon)\max_{a'} Q(s',a') + \tfrac{\varepsilon}{2}\textstyle\sum_{a'} Q(s',a')\Big]. \tag{3}$$

T_ε es una contracción de módulo γ con punto fijo único q_ε, el valor de la mejor política ε-greedy. Con ε constante, SARSA fluctúa alrededor de q_ε cuando la política greedy permanece estable; con α grande, los cambios de política pueden desplazar incluso su media. No se garantiza convergencia exacta con α constante. Bajo condiciones estándar, SARSA converge a q_* con probabilidad 1 si la exploración es GLIE ($\varepsilon_k \to 0$ y todos los pares se visitan infinitas veces) y las tasas de aprendizaje cumplen, para cada par, $\sum_k \alpha_k = \infty$ y $\sum_k \alpha_k^2 < \infty$. Con α constante y targets aleatorios, Q no se detiene nunca: fluctuar es el comportamiento esperado, no un error.

3.2. Convergencia en s_6 y s_{13}

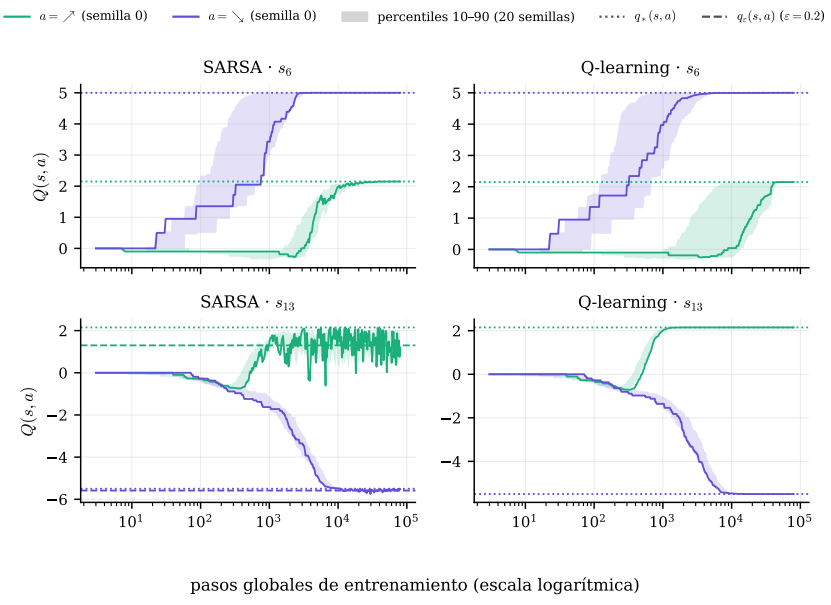


Figura 2: Evolución de $Q(s_6,\cdot)$ y $Q(s_{13},\cdot)$ frente a pasos globales (configuración base).

Estado s_6 (Figura 2, izquierda). Para $\searrow$, el target es siempre 5, pues termina en el objetivo. Para $\nearrow$, depende de $Q(s_3,A')$: durante el aprendizaje puede variar porque las dos acciones de

s_3, aunque producen la misma transición, aún tienen estimaciones distintas. Al igualarse estas, desaparece dicha variabilidad y $q_\varepsilon(s_6, \cdot) = q_*(s_6, \cdot) = (2.15,\ 5)$.

- $Q(s_6, \searrow) \leftarrow Q + \alpha(5 - Q)$: el error decae como $5(1-\alpha)^n$ y entra en la banda ± 0.1 tras $\ln(0.02)/\ln(0.9) \approx 38$ visitas (mediana medida: 40; 1 873 pasos).
- $Q(s_6, \nearrow)$ empieza *negativa* (mínimo medio -0.31): su target $-1+\gamma Q(s_3, \cdot)$ usa $Q(s_3) \approx 0$, así que el -1 llega antes que el $+5$. Se vuelve positiva cuando el valor se propaga $s_7 \to s_3 \to s_6$ y alcanza 2.15 tarde (mediana 10 372 pasos), porque al ser no greedy solo se elige al explorar: 693 visitas frente a 6 160 de $\searrow$. Su aprendizaje requiere más pasos globales por las escasas visitas y por el retraso inicial de la propagación desde sus sucesores.

Estado s_{13}, acción $\searrow$. Lleva a s_{18}, desde donde solo se puede chocar. Con probabilidad 0.9 el agente elige después $\searrow$ (target $-1+0.9(-5) = -5.5$) y con 0.1 elige $\nearrow$ ($-1+0.9(-5.95) = -6.355$), luego $q_\varepsilon(s_{13}, \searrow) = -5.586$. Medimos -5.583 (media temporal del último 25 %, 20 semillas). El estimador fluctúa alrededor de -5.59, no de -5.5, y sus caídas se deben a las actualizaciones asociadas a decisiones exploratorias.

Estado s_{13}, acción $\nearrow$. Lleva a s_{11}, una bifurcación: $\nearrow$ conduce al objetivo ($Q(s_{11}, \nearrow) = 3.5$) y $\searrow$ a un choque seguro ($Q(s_{11}, \searrow) = -5.95$). El target vale 2.15 con probabilidad 0.9 y -6.355 con 0.1:

$$q_\varepsilon(s_{13}, \nearrow) = -1 + 0.9\,(0.9 \cdot 3.5 + 0.1 \cdot (-5.95)) = 1.2995 < q_*(s_{13}, \nearrow) = 2.15. \tag{4}$$

La media medida es 1.302, lo que confirma la predicción. Fases: hasta $\sim$500 pasos ambas Q son negativas (solo se han propagado los -1); entre 500 y 3 000 pasos $Q(s_{13}, \nearrow)$ sube a medida que s_{11} aprende; después oscila alrededor de 1.30. Cada punto de la curva es un valor instantáneo, no el esperado: una sola elección exploratoria en s_{11} lo baja en $\alpha(Q+6.355) \approx 0.77$, y la recuperación es geométrica.

3.3. Influencia de los hiperparámetros

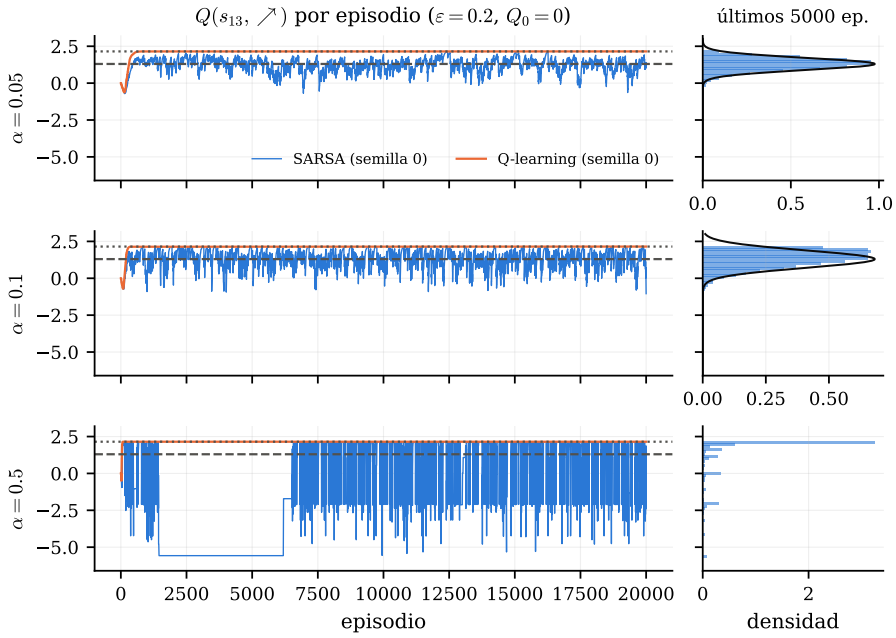


Figura 3: $Q(s_{13}, \nearrow)$ de SARSA y Q-learning para tres valores de α. Derecha: distribución en los últimos 5 000 episodios (10 semillas) y aproximación normal con media y varianza estacionarias teóricas para $\alpha \leq 0.1$. Líneas: q_* (puntos) y q_ε (trazos).

	SARSA: $Q(s_{13}, \nearrow)$			QL	Retorno greedy		Política estable (ep.)	
α	σ teórica	σ emp.	media emp.	media	SARSA	QL	SARSA	QL
0.01	0.18	0.17	1.33	2.15	1.50	1.50	17 187	17 602
0.05	0.41	0.41	1.29	2.15	1.50	1.50	3 436	3 368
0.1	0.59	0.58	1.31	2.15	1.50	1.50	1 597	1 414
0.5	1.47	1.66	1.19	2.15	1.17	1.50	1/10 nunca	202
1.0	2.55	4.12	−3.17	2.15	−4.90	1.50	10/10 nunca	75

Tabla 2: Efecto de α (10 semillas). σ: desviación típica estacionaria de $Q(s_{13}, \nearrow)$. Política estable: episodio desde el que la acción greedy es óptima en los 17 estados alcanzables.

Tasa de aprendizaje. En $(s_{13}, \nearrow)$, el siguiente movimiento desde s_{11} hace que SARSA reciba un target de 2.15 con probabilidad 0.9 o de −6.355 con probabilidad 0.1. Con α pequeño, cada actualización modifica poco el estimador; con α mayor, las exploraciones producen caídas y recuperaciones más bruscas. La Tabla 2 muestra que la dispersión calculada a partir de esas actualizaciones es cercana a la medida para $\alpha \leq 0.1$ (0.18/0.17, 0.41/0.41, 0.59/0.58). Las medias obtenidas, entre 1.29 y 1.33, siguen próximas a $q_\varepsilon = 1.2995$. Por tanto, aumentar α acelera el aprendizaje, pero también aumenta las oscilaciones: la política alcanza la optimalidad tras 17 187 episodios con $\alpha = 0.01$ y tras 1 597 con $\alpha = 0.1$.

Con $\alpha \geq 0.5$ la aproximación falla porque el ruido realimenta la política. En la semilla 0 con $\alpha = 0.5$ (Figura 3, segmento plano), dos exploraciones seguidas en s_{11} hunden $Q(s_{13}, \nearrow)$ por debajo de $Q(s_{13}, \searrow)$ en el episodio 1 444. El error se propaga aguas arriba: en s_9, s_4 y s_{12} chocar (−5) pasa a parecer mejor que continuar (≈ -5.5). s_{13} apenas vuelve a visitarse y el error persiste unos 4 800 episodios. En esa semilla, el 11 % de las evaluaciones posteriores al episodio 1 000 son subóptimas. Con $\alpha = 1$, Q es la última muestra: el choque tiene valor determinista −5 y continuar vale lo que dio la última muestra, a menudo contaminada por un error exploratorio aguas abajo. La política greedy acaba chocando desde los cuatro estados iniciales (retorno −4.90).

Número de episodios. Con α y ε constantes, entrenar N episodios es exactamente el prefijo de un entrenamiento más largo con la misma semilla (comprobado). El presupuesto no cambia la dinámica, solo dónde se detiene. Con 500 episodios ($\approx$ 2 000 pasos) $Q(s_6, \searrow)$ está prácticamente aprendida (mediana: 1 873 pasos) y $Q(s_{13}, \nearrow)$ ronda q_ε. Con 2 000, la política es óptima en los 17 estados (mediana: episodio 1 509). Tras $\sim$10 000 episodios, los valores seguidos de SARSA muestran sobre todo fluctuaciones, mientras que algunos pares raros de Q-learning aún pueden reducir su error. *La política alcanza la optimalidad mucho antes de que los estimadores se estabilicen*; con α constante, SARSA mantiene fluctuaciones.

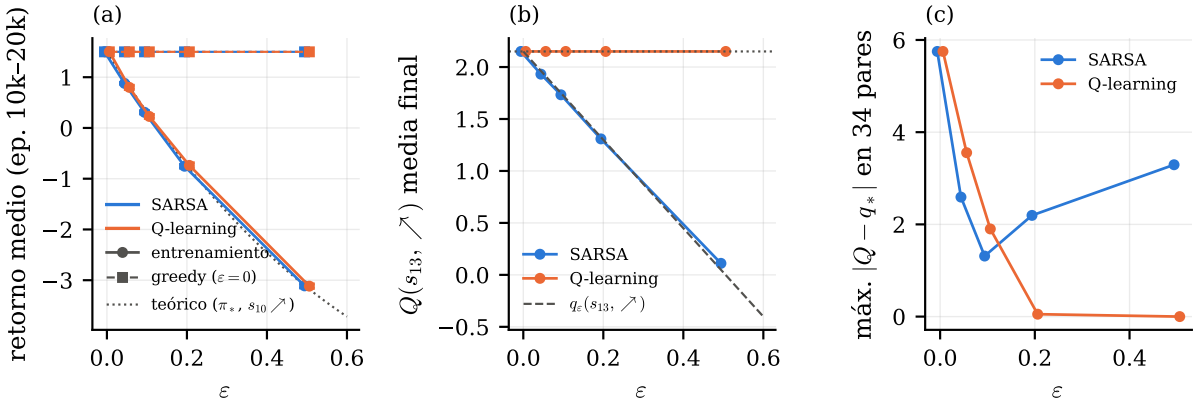


Figura 4: Efecto de ε (10 semillas, $\alpha = 0.1$, $Q_0 = 0$). (a) Retorno de entrenamiento y greedy, con la predicción exacta para la política ε-greedy de π_*. (b) Media final de $Q(s_{13}, \nearrow)$ y curva $q_\varepsilon(s_{13}, \nearrow)$. (c) Error máximo frente a q_* en los pares alcanzables.

Exploración. ε sí cambia el objetivo: $q_\varepsilon(s_{13}, \nearrow) = -1 + 0.9\,[(1 - \frac{\varepsilon}{2})3.5 - \frac{\varepsilon}{2}5.95]$ es lineal en ε, y las medias empíricas siguen esa recta (Figura 4b). Más exploración aumenta el impacto de las decisiones arriesgadas: la tasa de éxito en entrenamiento cae del 92.6 % ($\varepsilon = 0.05$) al 72.8 % (0.2) y al 42.5 % (0.5). El retorno coincide con el valor exacto de la conducta ε-greedy (Figura 4a). La política greedy es óptima en todos los casos, por lo que la pérdida se debe a explorar, no a aprender mal.

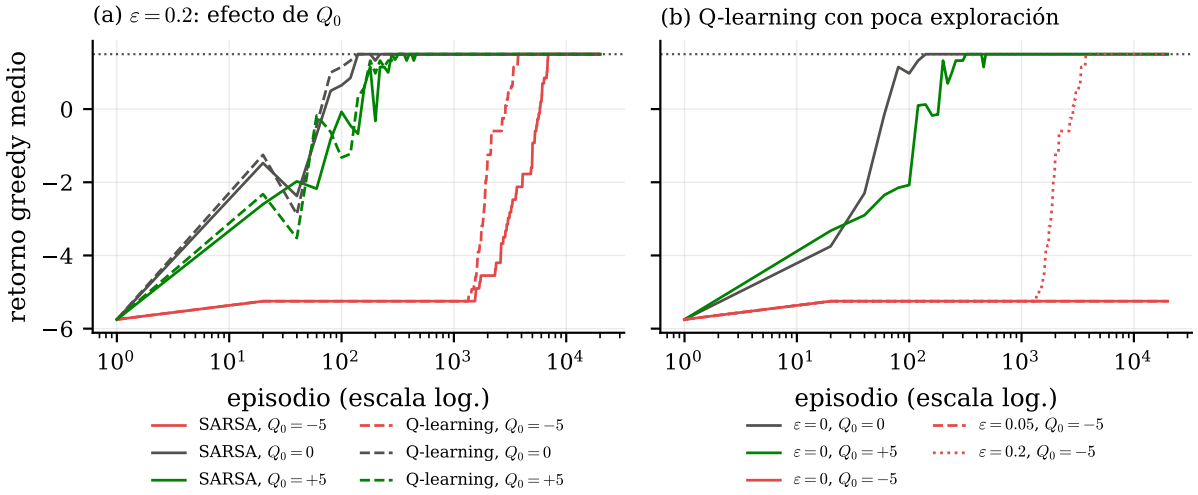


Figura 5: Retorno greedy medio desde s_{init} (10 semillas). (a) Efecto de Q_0 con $\varepsilon = 0.2$. (b) Q-learning con poca exploración (con $\varepsilon = 0$ SARSA es idéntico).

Inicialización. $Q_0 = 0$ es optimista para 19 de los 34 pares alcanzables ($q_* < 0$): una acción que acaba mal baja de 0 y la alternativa no probada pasa a ser greedy. Esto es exploración dirigida. Con $Q_0 = -5$ (pesimista), chocar tiene target $-5 = Q_0$ y no cambia nada, mientras que dar un paso tiene target $-1 + 0.9(-5) = -5.5 < -5$. El agente prefiere chocar hasta que la exploración descubre el objetivo y el valor se propaga: la evaluación greedy tarda 5 790 episodios en ser óptima (80 con $Q_0 = 0$; Figura 5a). $Q_0 = +5$ aprende igual de rápido y prueba más al principio (retorno -1.58 frente a -1.43 en 500 episodios). Además, los pares con $q_* = 5$ ($s_6\searrow$, s_7, $s_{14}\nearrow$) empiezan ya en su valor exacto. Tras suficientes visitas, Q_0 solo deja huella en los pares poco visitados, con un factor $(1 - \alpha)^N$.

Interacciones. La combinación peligrosa es poca exploración con pesimismo: con $\varepsilon = 0$ y $Q_0 = -5$ el agente choca en todos los episodios, y con $\varepsilon = 0.05$ el éxito es del 0.06 % tras 20 000 episodios (Figura 5b; SARSA se comporta igual), porque propagar el valor hasta s_{init} exige varias exploraciones consecutivas. El optimismo puede sustituir a la exploración: con $\varepsilon = 0$ y $Q_0 = +5$ la política es óptima en 130 episodios. Con α y ε altos (0.5/0.5), SARSA acumula ambos ruidos: retorno greedy final 0.38 frente a 1.50 con $\alpha = 0.05$.

Exploración decreciente (extensión). Con $\varepsilon_k = 0.2/(1 + k/1000)$, que acaba en 0.0095, la media temporal de $Q(s_{13}, \nearrow)$ alcanza 2.10 (desviación típica 0.15), cerca de $q_* = 2.15$. Este resultado es empírico: aunque ε disminuye progresivamente, eso no garantiza que el agente siga visitando infinitas veces todos los pares estado-acción. Por tanto, no podemos asegurar la convergencia teórica solo por reducir la exploración.

4. Q-learning

4.1. Fundamentos

Q-learning actualiza con el máximo del estado siguiente:

$$Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma \max_{a'} Q(S',a') - Q(S,A)\big]. \tag{5}$$

Es *off-policy*: la conducta es ε-greedy, pero el target evalúa la política greedy, la acción que se ejecute después no interviene. Su valor esperado es la ecuación de optimalidad (1) (T_0, una contracción con punto fijo q_*). Converge a q_* con probabilidad 1 si todos los pares se visitan infinitas veces y, para cada par, $\sum_k \alpha_k = \infty$ y $\sum_k \alpha_k^2 < \infty$. En este entorno determinista, condicionado a la tabla Q el target no tiene ruido de transición. Una vez exactos los sucesores, $|Q_{n+1} - q_*| = (1-\alpha)|Q_n - q_*|$ en cada visita. Como el grafo es acíclico, una inducción desde los estados terminales justifica la convergencia a q_* para $0 < \alpha \leq 1$ en los pares visitados infinitamente. Con $\varepsilon > 0$ fijo estos son los 34 pares alcanzables; con cobertura insuficiente la conclusión no vale.

4.2. Convergencia en s_6 y s_{13}

En s_6 (Figura 2, derecha) ambos algoritmos comparten el target de $\searrow$, que termina en el objetivo. Para $\nearrow$ pueden diferir transitoriamente: SARSA usa $Q(s_3, A')$ y Q-learning $\max_a Q(s_3, a)$. Como las acciones de s_3 producen la misma transición, sus estimaciones acaban igualándose. Para $\searrow$ necesitan las mismas visitas (38 para entrar en la banda); en pasos globales Q-learning tarda más (3 759 frente a 1 873 en $\searrow$; 38 939 frente a 10 372 en $\nearrow$), porque inicialmente visita preferentemente s_{14} y no s_6 (Sección 5).

En s_{13} el target de $\nearrow$ usa $\max_a Q(s_{11}, a) = 3.5$, aunque después la conducta explore $\searrow$ en s_{11}. Por eso $Q(s_{13}, \nearrow) \to 2.15$ con desviación final $2 \cdot 10^{-13}$, frente a 0.58 en SARSA, y $Q(s_{13}, \searrow) \to -5.5$. Las fases son las mismas que en SARSA (valores negativos, propagación, final), pero el final es un punto fijo exacto.

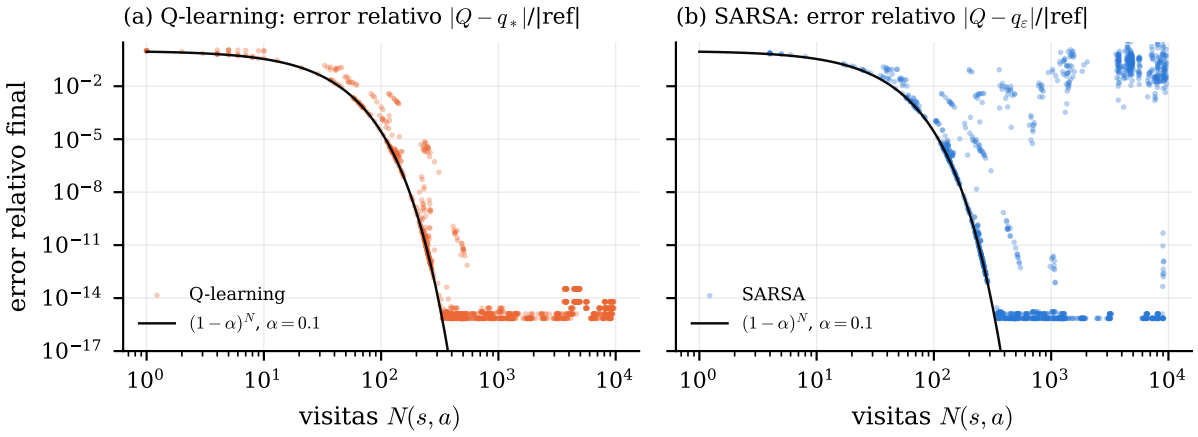


Figura 6: Error relativo final frente a visitas, para todos los pares alcanzables ($\alpha = 0.1$, $\varepsilon \in \{0.05, 0.1, 0.2, 0.5\}$, 10 semillas). Referencia: q_* para Q-learning, q_ε para SARSA.

La Figura 6a muestra que el error de cada par sigue $(1-\alpha)^N$ hasta la precisión de máquina (10^{-16}). Los puntos desplazados a la derecha son pares cuyos sucesores convergieron más tarde. Esto explica los errores residuales: $Q(s_3, \nearrow)$, con 37 visitas en la semilla 0, vale 3.42 (error $0.08 \approx 3.5 \cdot 0.9^{37}$). En SARSA (Figura 6b), los pares con target determinista siguen la misma curva, pero aquellos cuyo resultado depende de decisiones posteriores con recompensas distintas mantienen oscilaciones entre 10^{-2} y 1.

4.3. Influencia de los hiperparámetros

α. En las configuraciones ensayadas, aumentar α acelera los backups deterministas, sin el coste de varianza de SARSA: la política es óptima en los 17 estados tras 1 414 episodios con $\alpha = 0.1$, 202 con 0.5 y 75 con $\alpha = 1$ (Tabla 2). Con $\alpha = 1$ cada actualización es un *backup* de Bellman de una transición observada, como una Value Iteration asíncrona en este MDP determinista. No debe generalizarse este efecto a targets aleatorios.

ε. No cambia el objetivo ($Q(s_{13}, \nearrow) = 2.15$ para todo ε, Figura 4b), pero sí la *cobertura*. Las acciones no greedy solo se aprenden explorando. Con $\varepsilon = 0.05$, $Q(s_6, \nearrow) = 0.08$ tras 20 000 episodios (frente a 2.15) y el error máximo es 3.56; con $\varepsilon = 0.5$ es $5 \cdot 10^{-11}$ (Figura 4c). El coste de explorar recae en el retorno de entrenamiento, igual que en SARSA.

Q_0 y $\varepsilon = 0$. $Q_0 = -5$ retrasa el aprendizaje (2 840 episodios hasta la política greedy óptima, Figura 5a) y $Q_0 = +5$ da el menor error final (0.001). Con $\varepsilon = 0$ y $Q_0 = +5$ el retorno greedy es óptimo, pero 3 pares no se visitan nunca y algunos estados fuera de la trayectoria conservan una acción incorrecta (error máximo 10.5). Una política óptima *sobre su trayectoria* no implica valores ni acciones correctos en todos los estados.

5. Comparación entre SARSA y Q-learning

Respuestas a las preguntas del enunciado, que justificamos a continuación con los cuatro criterios. *¿Misma política?* No necesariamente: ambas aprenden políticas óptimas, pero pueden diferir en s_{10}, donde las dos acciones tienen el mismo valor óptimo. *¿Mismos valores?* No: Q-learning se aproxima a q_* y SARSA fluctúa alrededor de q_ε. *¿Mejor retorno en entrenamiento?* SARSA, en la fase intermedia (500–10 000 episodios), porque evita la ruta en la que explorar es más caro. Al finalizar el entrenamiento, ambos alcanzan el mismo retorno greedy óptimo de 1.5.

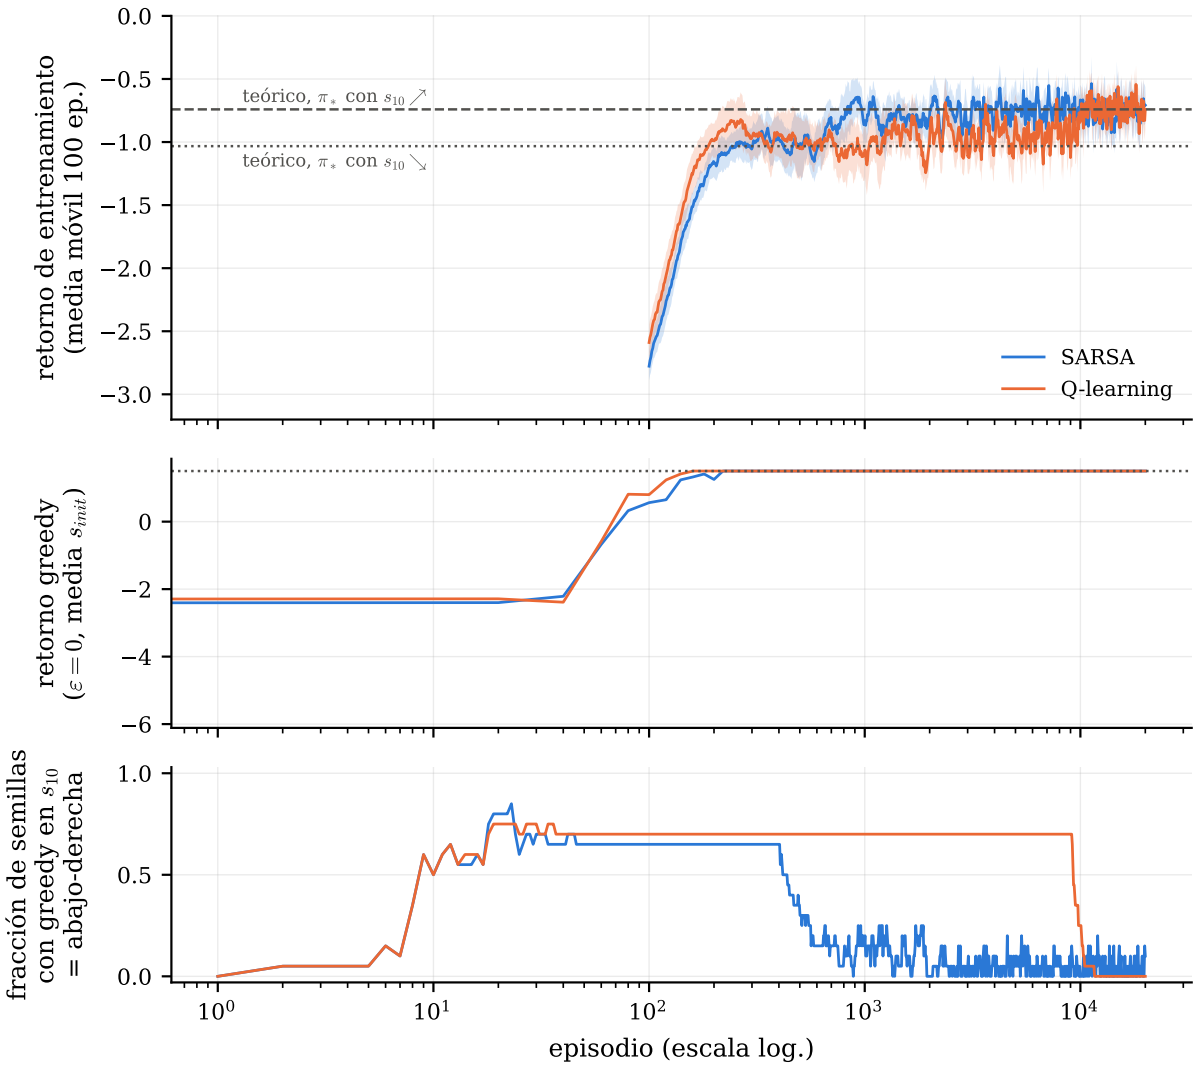


Figura 7: Configuración base, 20 semillas. Arriba: retorno de entrenamiento (media móvil de 100 episodios, IC 95 %) y valor exacto de la conducta ε-greedy de π_* según la ruta elegida en s_{10}. Centro: retorno greedy. Abajo: fracción de semillas cuya acción greedy en s_{10} es ↘.

	Retorno medio					greedy(s_{10}) =↘	
Episodios	SARSA	QL	Dif. [IC 95 %]	p	SARSA mejor	SARSA	QL
[0, 100)	−2.78	−2.59	−0.19 [−0.31, −0.07]	0.008	5/20	61 %	65 %
[100, 500)	−1.05	−0.99	−0.06 [−0.15, 0.02]	0.157	6/20	60 %	70 %
[500, 10 000)	−0.76	−0.94	0.18 [0.12, 0.24]	< 0.001	15/20	6 %	67 %
[10 000, 20 000)	−0.76	−0.75	−0.02 [−0.04, 0.00]	0.130	7/20	4 %	1 %

Tabla 3: Retorno de entrenamiento por fases (20 semillas pareadas). Dif.: SARSA − QL con IC bootstrap al 95 %; p: test de permutación de signos.

A. Eficiencia muestral. Con $\alpha \leq 0.1$ no hay diferencias relevantes (Figura 8). Ambos alcanzan el retorno greedy óptimo desde s_{init} hacia el episodio 80 ($\approx$ 300–450 pasos) y la acción óptima en los 17 estados hacia el 1 500. La diferencia aparece con α: entre los α ensayados, Q-learning reduce monótonamente los pasos hasta una política óptima en los 17 estados, gracias a los backups deterministas; esta mejora no es estrictamente monótona para el retorno greedy desde s_{init}. SARSA empeora desde $\alpha = 0.5$ por el ruido de su target. Para un mismo par con target determinista ambos necesitan las mismas visitas. Las diferencias en pasos se deben a cuántas veces visita cada conducta ese par (caso de s_6). En ambos, la política greedy alcanza antes la optimalidad que la estabilización de los valores.

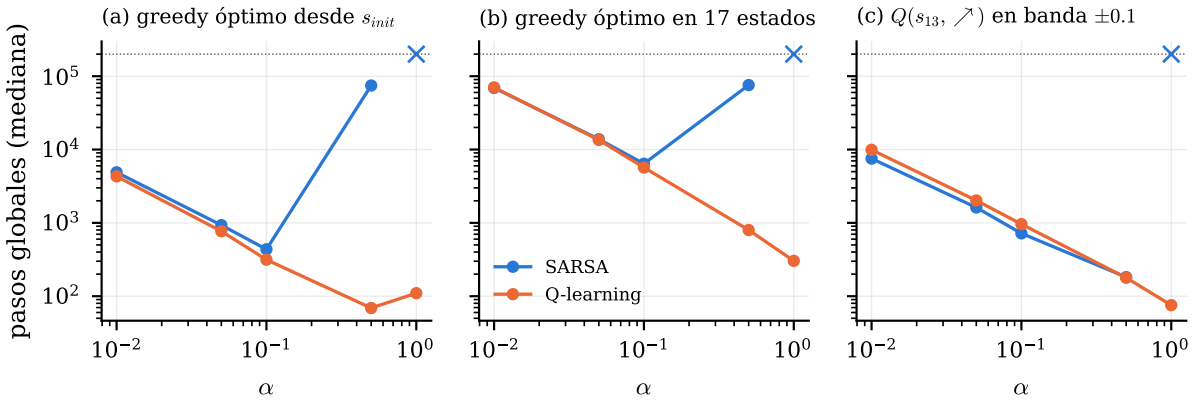


Figura 8: Pasos globales (mediana: 10 semillas por α, 20 en la base) hasta que, de forma estable, (a) la política greedy es óptima desde s_{init} y (b) en los 17 estados alcanzables, y (c) hasta que $Q(s_{13}, \nearrow)$ entra por primera vez en ±0.1 de su referencia. ×: la mayoría de semillas no lo alcanza.

B. Evolución del retorno (Figura 7, Tabla 3). Tras el aprendizaje, ambos alcanzan el mismo retorno greedy óptimo de 1.5, aunque inicialmente hay diferencias transitorias. En entrenamiento distinguimos tres fases.

- *Inicial (0–100 episodios).* Ambos chocan con frecuencia (retorno ≈ -2.7). Q-learning es algo mejor (-0.19, $p = 0.008$), lo que es coherente con que el máximo propaga antes el valor del objetivo. La ventaja de su política greedy entre los episodios 20 y 200 no es significativa ($p = 0.08$).
- *Intermedia (500–10 000).* SARSA obtiene 0.18 más por episodio (IC $[0.12, 0.24]$, $p < 0.001$, 15 de 20 semillas). La causa es s_{10}: la acción greedy de Q-learning es ↘ en el 67 % de los casos, la de SARSA en el 6 %. Explorando en s_{14} se pierden 11 puntos (choque en lugar de +5), y en s_6 solo 2. El valor exacto de la conducta ε-greedy es -0.741 por s_6 frente a -1.033 por s_{14}, y, considerando las frecuencias de esa ruta en ambos algoritmos, la diferencia prevista es $(0.671 - 0.062) \times 0.2916 \approx 0.178$, muy próxima a la observada (0.185). SARSA *ve* este riesgo, $q_\varepsilon(s_{10}, \nearrow) = 3.24 > q_\varepsilon(s_{10}, \searrow) = 2.56$; para Q-learning ambas valen 3.5.

- *Final (10 000–20 000).* La diferencia desaparece ($p = 0.13$), pero no porque Q-learning aprenda el riesgo.

¿Por qué Q-learning elige s_{14} y por qué deja de hacerlo? Con $Q_0 = 0$, `argmax` desempata hacia ↗. En s_{14}, ↗ es la acción que llega al objetivo y $Q(s_{14}, ↗)$ aprende el $+5$ enseguida; en s_6, ↗ es el rodeo. Al principio $\max Q(s_{14}) > \max Q(s_6)$, así que ↘ domina en s_{10}. Al recibir más actualizaciones, queda más cerca de 3.5 por debajo y se mantiene greedy. Es una preferencia que se autorrefuerza. Hacia el episodio 9 300, tras suficientes visitas a la acción minoritaria, ambas estimaciones se vuelven *idénticas entre sí* en doble precisión (en la semilla 0 terminan en 3.4999999999999956, no en 3.5 exacto). `argmax` resuelve entonces ese empate hacia ↗. Es un efecto del redondeo numérico, no un cambio de preferencia debido al aprendizaje del riesgo. Con $\varepsilon = 0.05$ ese empate no llega en 20 000 episodios y la ventaja de SARSA persiste hasta el final ($+0.08$, $p = 0.004$; predicción 0.9×0.10).

C. Exploración frente a explotación. SARSA incorpora en sus valores su propia exploración futura: estima la conducta que realmente ejecuta y prefiere rutas robustas a los errores. Q-learning actualiza hacia el máximo greedy, sin incorporar en el target el coste de la exploración posterior; con suficiente cobertura, se aproxima a q_* incluso con $\varepsilon = 0.5$, pero no distingue rutas igual de buenas sin exploración y distintas con ella. Las políticas difieren solo donde los $\arg\max$ de q_ε y q_* difieren. Lo comprobamos para $\varepsilon \leq 0.5$ y r_{obs} hasta -50: solo ocurre en s_{10}, que es un empate en q_*, así que ambas políticas finales son óptimas. Explorar demasiado poco puede bloquear el aprendizaje ($\varepsilon = 0$, $Q_0 = -5$); explorar demasiado hunde el retorno de entrenamiento (-3.1 con $\varepsilon = 0.5$) y aleja a SARSA de q_*, aunque mejora la cobertura de Q-learning.

D. Valores finales (Tabla 4).

- *Q-learning:* los 34 pares alcanzables se aproximan a q_* en los 20 000 episodios. El error máximo de la configuración base es ≤ 0.08 y siempre aparece en pares con menos de 100 visitas (s_3 en 16 de 20 semillas).
- *SARSA:* fluctúa alrededor de q_ε (por ejemplo, -1.815 frente a -1.815 en s_4↘; 1.30 en s_{13}↗). Difiere de q_* cuando las decisiones posteriores pueden producir recompensas diferentes: s_0↘ 0.05 frente a 0.94, s_4↘ -1.81 frente a -0.16. Los pares cuya trayectoria posterior es determinista (s_6, s_{11}, s_{14}, s_{18}, última columna) coinciden en ambos.
- *Sesgo de la media temporal en s_{10}:* para SARSA, la media de $Q(s_{10}, ↘)$ por episodios (2.32) queda por debajo de $q_\varepsilon = 2.56$. Esto no implica otro punto fijo: cuando la acción es greedy recibe actualizaciones frecuentes, mientras que sus estimaciones bajas pueden persistir más episodios al seleccionarse principalmente por exploración. En los registros, una media aproximada ponderada por visitas asciende a 2.50, frente a 2.32 al ponderar uniformemente por episodios. Así, el procedimiento de muestreo afecta a la media observada, que no debe confundirse con el valor esperado del target.
- *Inalcanzables:* s_2, s_{16} y s_{17} conservan Q_0 en los dos algoritmos. Es falta de experiencia, no un error de estimación.

	$a = \nearrow$					$a = \searrow$				
s	q_*	q_ε	SARSA (σ)	QL	N S/QL	q_*	q_ε	SARSA (σ)	QL	N S/QL
s_0	−5.00	−5.00	−5.00 (0.00)	−5.00	498/504	0.94	0.05	0.05 (0.42)	0.94	4498/4501
s_1	−5.00	−5.00	−5.00 (0.00)	−5.00	255/253	−5.00	−5.00	−5.00 (0.00)	−5.00	254/252
s_3	3.50	3.50	3.49 (0.01)	3.42	74/60	3.50	3.50	3.50 (0.00)	3.46	613/360
s_4	−5.50	−5.50	−5.50 (0.00)	−5.50	510/505	−0.16	−1.81	−1.81 (0.40)	−0.16	4496/4481
s_5	−5.00	−5.00	−5.00 (0.00)	−5.00	902/910	2.15	1.86	1.83 (0.13)	2.15	8063/8074
s_6	2.15	2.15	2.15 (0.00)	2.15	693/436	5.00	5.00	5.00 (0.00)	5.00	6159/3876
s_7	5.00	5.00	5.00 (0.00)	5.00	6520/6274	5.00	5.00	5.00 (0.00)	5.00	725/702
s_8	0.94	0.05	0.02 (0.43)	0.94	4476/4491	−5.00	−5.00	−5.00 (0.00)	−5.00	506/501
s_9	−5.00	−5.00	−5.00 (0.00)	−5.00	899/904	0.94	−0.45	−0.44 (0.53)	0.94	8109/8099
s_{10}	3.50	3.24	3.23 (0.19)	3.50	6854/4319	3.50	2.56	2.32 (0.56)	3.50	1240/3763
s_{11}	3.50	3.50	3.50 (0.00)	3.50	6544/6554	−5.95	−5.95	−5.95 (0.00)	−5.95	728/727
s_{12}	−0.16	−1.81	−1.81 (0.39)	−0.16	4532/4529	−5.00	−5.00	−5.00 (0.00)	−5.00	508/504
s_{13}	2.15	1.30	1.30 (0.58)	2.15	7267/7286	−5.50	−5.59	−5.58 (0.06)	−5.50	818/818
s_{14}	5.00	5.00	5.00 (0.00)	5.00	1117/3369	−5.50	−5.50	−5.50 (0.00)	−5.50	122/384
s_{15}	−5.50	−5.50	−5.50 (0.00)	−5.50	475/488	−5.50	−5.50	−5.50 (0.00)	−5.50	359/355
s_{18}	−5.95	−5.95	−5.95 (0.00)	−5.95	110/111	−5.00	−5.00	−5.00 (0.00)	−5.00	701/707
s_{19}	−5.00	−5.00	−5.00 (0.00)	−5.00	595/839	−5.00	−5.00	−5.00 (0.00)	−5.00	356/379

Tabla 4: Valores finales (media temporal del último 25 %, 20 semillas; entre paréntesis, desviación típica temporal de SARSA) y visitas medianas N (SARSA/QL). Estados inalcanzables omitidos: $Q = Q_0 = 0$ y $N = 0$ en ambos.

En cuanto a las políticas, las finales son óptimas en todos los estados alcanzables y coinciden salvo en s_{10} en 2 de 20 semillas. En ellas SARSA acaba en $\searrow$, igualmente óptima, porque $Q(s_{10}, \searrow)$ fluctúa; Q-learning elige $\nearrow$ en 20/20 por el desempate exacto. Las acciones de s_1, s_{15} y s_{19} siguen alternando hasta el final sin consecuencias, porque ambas son equivalentes.

6. Conclusiones

- **Cada algoritmo estima una cosa distinta.** Q-learning usa el operador de optimalidad y se aproxima a q_* en todos los pares alcanzables del experimento; la convergencia exacta requeriría prolongar las visitas. SARSA muestrea T_ε y fluctúa alrededor de q_ε. Ejemplo: $Q(s_{13}, \nearrow)$ vale 1.30 en SARSA frente a $q_* = 2.15$, y la diferencia es exactamente el coste esperado de explorar en s_{11}.
- **La política greedy alcanza la optimalidad antes que los valores** (unos 1 500 episodios frente a unos 10 000 para algunos estimadores de Q-learning). Las acciones greedy en estados con empate pueden seguir alternando y SARSA mantiene fluctuaciones. Los pares no greedy y los inalcanzables muestran que convergencia exige visitas: el error decae como $(1 - \alpha)^N$.
- **Efecto distinto de α en este entorno.** En SARSA, un α grande hace que las decisiones exploratorias provoquen cambios bruscos en Q; con $\alpha \geq 0.5$, observamos pérdidas de estabilidad. En Q-learning, los targets deterministas permiten aprender más rápido al aumentar α, aunque esto no tiene por qué ocurrir en entornos estocásticos.
- **La ventaja intermedia de SARSA en entrenamiento se explica por las distintas rutas en s_{10}**, donde explorar tiene costes asimétricos. La diferencia de retorno observada, 0.185 por episodio, coincide aproximadamente con la predicción del modelo (0.178). La ventaja desaparece al final porque las estimaciones de Q-learning acaban empatando por el redondeo numérico, no porque aprenda a tener en cuenta el riesgo de explorar.
- **Exploración e inicialización interactúan.** $Q_0 = 0$ ya es optimista en este entorno; el pesimismo con poca exploración ($Q_0 = -5$, $\varepsilon \leq 0.05$) mantiene al agente casi siempre chocando durante los 20 000 episodios ensayados.

7. Uso de la IA

- Ayuda en la corrección ortográfica y en la redacción científica, mejorando la cohesión, la claridad y las explicaciones del texto.
- Ayuda a la hora de generación de plots.
- Ayuda en la generación de tablas y fórmulas en Latex