Aprendizaje por Refuerzo

Grado en Ingeniería Matemática e Inteligencia Artificial (IMAT) – 4º A
Universidad Pontificia Comillas, ICAI

Práctica 2:
RL tabular sin modelo: SARSA y Q-learning

Informe de laboratorio

Jorge Carnicero
Jorge González
Andrés Gil

Fecha de entrega:
octubre de 2026

Índice

1. Introducción y metodología **1**

2. Trabajo previo: valores óptimos q_* **1**

3. SARSA **3**
3.1. Fundamentos e implementación 3
3.2. Convergencia en s_6 y s_{13} 3
3.3. Influencia de los hiperparámetros 4

4. Q-learning **7**
4.1. Fundamentos 7
4.2. Convergencia en s_6 y s_{13} 7
4.3. Influencia de los hiperparámetros 8

5. Comparación entre SARSA y Q-learning **8**

6. Conclusiones **11**

1. Introducción y metodología

En la Práctica 1 resolvimos *Jump To The Goal* con programación dinámica, usando el modelo $p(s', r \mid s, a)$. Ahora el agente no lo conoce: aprende solo de las transiciones $(S_t, A_t, R_{t+1}, S_{t+1})$ que genera. Implementamos los dos métodos de diferencias temporales (TD) tabulares, SARSA y Q-learning, y analizamos qué estiman, cuánta experiencia necesitan y por qué difieren.

Configuración basal. Entorno determinista, $\gamma = 0.9$, $r_s = -1$, $r_{obs} = -5$, $r_{goal} = +5$, $\varepsilon = 0.2$, $\alpha = 0.1$ y $Q_0 = 0$ (valores por defecto de `main.py`), 20 000 episodios ($\approx 80\,000$ pasos) y estado inicial uniforme en $s_{init} = \{s_0, s_4, s_8, s_{12}\}$.

Metodología. (i) Validamos la implementación con 32 comprobaciones automáticas del script `validate_algorithms.py`: reglas de actualización con azar guionizado, ausencia de *bootstrapping* en transiciones terminales, desempate de `argmax`, y que con $\varepsilon = 0$ ambos algoritmos generan exactamente la misma tabla Q. (ii) Un ejecutor instrumentado llama a las funciones de episodio originales, reproduce bit a bit `main.py` y registra Q completa, visitas $N(s, a)$, retornos y una evaluación greedy ($\varepsilon = 0$) desde los cuatro estados iniciales cada 20 episodios. (iii) Cada configuración se repite con 10 semillas (20 en la basal), las mismas para ambos algoritmos, lo que permite comparaciones pareadas; damos medias, percentiles e intervalos bootstrap al 95 %. (iv) Las referencias teóricas se calculan con el modelo P, que nunca se entrega a los agentes. En total, 400 entrenamientos.

Distinguimos *pasos* (transiciones globales), *episodios* y *visitas* a un par. El *retorno* es la suma sin descuento de un episodio, como lo registra `entrenamiento.py`.

Reproducción (desde `lab2/experiments`)

```
python validate_algorithms.py
python run_experiments.py
python analyze_results.py
```

2. Trabajo previo: valores óptimos q_*

Con el modelo determinista, q_* cumple la ecuación de optimalidad de Bellman

$$q_*(s, a) = r(s, a) + \gamma \max_{a'} q_*(s', a'), \qquad q_*(T, \cdot) = 0. \tag{1}$$

El agente siempre avanza una columna (o cae una fila en la última), así que el grafo de transiciones es acíclico y q_* se obtiene hacia atrás: $q_*(s_7, \cdot) = 5$, $q_*(s_3, \cdot) = -1 + 0.9 \cdot 5 = 3.5$, $q_*(s_6, \nearrow) = -1 + 0.9 \cdot 3.5 = 2.15$, $q_*(s_{13}, \nearrow) = -1 + 0.9\, q_*(s_{11}, \nearrow) = 2.15$ y $q_*(s_{13}, \searrow) = -1 + 0.9 \max_a q_*(s_{18}, a) = -5.5$. La Tabla 1 recoge los 40 valores, que coinciden con $v_* = \max_a q_*$ de Policy y Value Iteration de la Práctica 1 en los 21 estados.

Del modelo extraemos cuatro propiedades que condicionan el aprendizaje (Figura 1):

- **Inalcanzables:** s_2, s_{16} y s_{17} solo tienen obstáculos como predecesores (s_{16} está en la primera columna pero fuera de s_{init}). Un método sin modelo no puede aprender sus Q, que se quedarán en Q_0. No es un fallo del algoritmo: su convergencia exige visitar cada par.
- **Sin ruta al objetivo:** desde s_1, s_{15}, s_{18} y s_{19} solo se puede chocar; lo óptimo es minimizar la pérdida (s_{18} choca ya, -5, en lugar de $s_{18} \to s_{15} \to s_{19} \to T$, -5.95).
- **Empates:** en s_1, s_3, s_7, s_{15} y s_{19} ambas acciones producen la misma transición; en s_{10}, en cambio, dos rutas distintas (s_6 y s_{14}) valen 3.5.
- **Riesgo exploratorio:** q_* supone que después se actuará de forma óptima. Un error desde s_{14} lleva a un choque seguro ($q_*(s_{14}, \searrow) = -5.5$), mientras que desde s_6 solo alarga el camino ($q_*(s_6, \nearrow) = 2.15$). Esta asimetría explicará la principal diferencia entre los algoritmos.

Estado	$q_*(s, \nearrow)$	$q_*(s, \searrow)$	$\mathcal{A}_*(s)$	Observación
s_0	−5.0000	0.9350	$\searrow$	
s_1	−5.0000	−5.0000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición
s_2	−5.0000	3.5000	$\searrow$	inalcanzable
s_3	3.5000	3.5000	$\nearrow, \searrow$	misma transición
s_4	−5.5000	−0.1585	$\searrow$	
s_5	−5.0000	2.1500	$\searrow$	
s_6	2.1500	5.0000	$\searrow$	
s_7	5.0000	5.0000	$\nearrow, \searrow$	misma transición
s_8	0.9350	−5.0000	$\nearrow$	
s_9	−5.0000	0.9350	$\searrow$	
s_{10}	3.5000	3.5000	$\nearrow, \searrow$	empate, rutas distintas
s_{11}	3.5000	−5.9500	$\nearrow$	
s_{12}	−0.1585	−5.0000	$\nearrow$	
s_{13}	2.1500	−5.5000	$\nearrow$	
s_{14}	5.0000	−5.5000	$\nearrow$	
s_{15}	−5.5000	−5.5000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición
s_{16}	−5.0000	−5.0000	$\nearrow, \searrow$	inalcanzable, sin ruta al objetivo, misma transición
s_{17}	3.5000	−5.0000	$\nearrow$	inalcanzable
s_{18}	−5.9500	−5.0000	$\searrow$	sin ruta al objetivo
s_{19}	−5.0000	−5.0000	$\nearrow, \searrow$	sin ruta al objetivo, misma transición

Tabla 1: Valores óptimos $q_*(s, a)$ ($\gamma = 0.9$, $r_s = -1$, $r_{obs} = -5$, $r_{goal} = +5$) y acciones óptimas $\mathcal{A}_*(s)$.

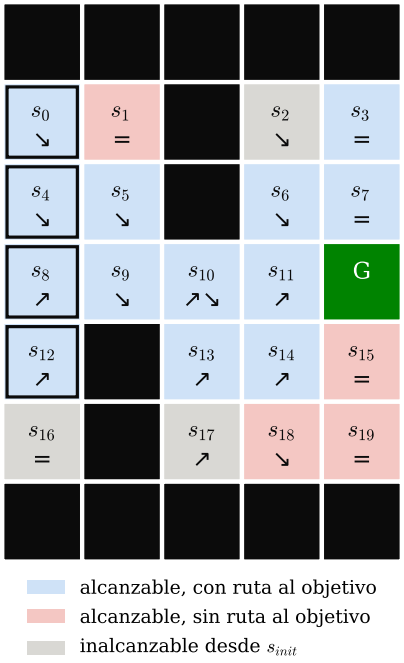


Figura 1: Estructura del entorno: acción óptima (=: ambas acciones producen la misma transición) y estados iniciales (recuadro).

3. SARSA

3.1. Fundamentos e implementación

SARSA es un método TD(0) de control: tras cada transición actualiza

$$Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma Q(S',A') - Q(S,A)\big], \tag{2}$$

donde A' es la acción que se ejecutará realmente en S', elegida con la misma política ε-greedy (*on-policy*). Si S' es terminal el target es solo R. El target sustituye el retorno completo por una estimación (*bootstrapping*), por lo que el $+5$ se propaga hacia atrás un estado por visita.

```
next_action = epsilon_greedy(Q, next_state, epsilon, rng)          # A' que se ejecutará
Q[state,action] += alpha*(reward + gamma*Q[next_state,next_action] - Q[state,action])
Q[state,action] += alpha*(reward - Q[state,action])                # si S' es terminal
```

Qué estima. Con transiciones deterministas, el valor esperado del target dado Q es

$$(T_\varepsilon Q)(s,a) = r + \gamma\Big[(1-\varepsilon)\max_{a'} Q(s',a') + \tfrac{\varepsilon}{2}\textstyle\sum_{a'} Q(s',a')\Big]. \tag{3}$$

T_ε es una contracción de módulo γ con punto fijo único q_ε, el valor de la mejor política ε-greedy. Con ε constante, SARSA fluctúa alrededor de q_ε, *no* de q_*. Converge a q_* con probabilidad 1 si la exploración es GLIE ($\varepsilon_k \to 0$ visitando todos los pares infinitas veces) y α cumple Robbins–Monro ($\sum \alpha_k = \infty$, $\sum \alpha_k^2 < \infty$) [3]. Con α constante y targets aleatorios, Q no se detiene nunca: fluctuar es el comportamiento esperado, no un error.

3.2. Convergencia en s_6 y s_{13}

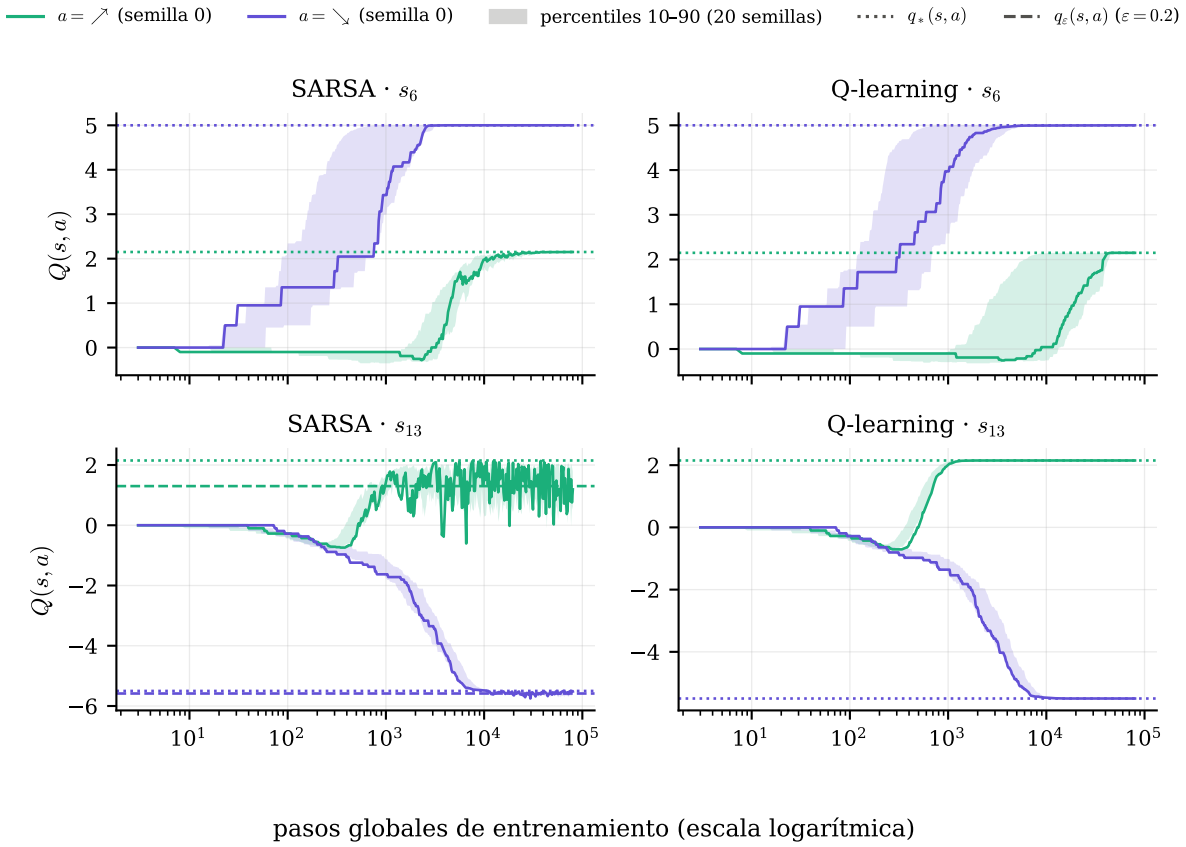


Figura 2: Evolución de $Q(s_6,\cdot)$ y $Q(s_{13},\cdot)$ frente a pasos globales (configuración basal).

Estado s_6 (Figura 2, izquierda). Ninguna acción depende de decisiones futuras: $\searrow$ termina en el objetivo y $\nearrow$ recorre $s_3 \to s_7 \to T$, donde las dos acciones de s_3 y s_7 hacen lo mismo. Por ello $q_\varepsilon(s_6, \cdot) = q_*(s_6, \cdot) = (2.15, 5)$ y SARSA converge sin ruido.

- $Q(s_6, \searrow) \leftarrow Q + \alpha(5 - Q)$: el error decae como $5(1-\alpha)^n$ (en nuestras notas escribimos γ en lugar de α) y entra en la banda ± 0.1 tras $\ln(0.02)/\ln(0.9) \approx 38$ visitas (mediana medida: 40; 1 873 pasos).
- $Q(s_6, \nearrow)$ empieza *negativa* (mínimo medio -0.31): su target $-1+\gamma Q(s_3, \cdot)$ usa $Q(s_3) \approx 0$, así que el -1 llega antes que el $+5$. Se vuelve positiva cuando el valor se propaga $s_7 \to s_3 \to s_6$ y alcanza 2.15 tarde (mediana 10 372 pasos), porque al ser no greedy solo se elige al explorar: 693 visitas frente a 6 160 de $\searrow$. Converge más despacio porque recibe menos muestras, no porque sea más difícil.

Estado s_{13}, acción $\searrow$. Lleva a s_{18}, desde donde solo se puede chocar. Con probabilidad 0.9 el agente elige después $\searrow$ (target $-1+0.9(-5) = -5.5$) y con 0.1 elige $\nearrow$ ($-1+0.9(-5.95) = -6.355$), luego $q_\varepsilon(s_{13}, \searrow) = -5.586$. Medimos -5.583 (media temporal del último 25 %, 20 semillas). En nuestras notas afirmábamos que convergía a -5.5: converge a -5.59, y las caídas que observábamos son esas muestras exploratorias.

Estado s_{13}, acción $\nearrow$. Lleva a s_{11}, una bifurcación: $\nearrow$ conduce al objetivo ($Q(s_{11}, \nearrow) = 3.5$) y $\searrow$ a un choque seguro ($Q(s_{11}, \searrow) = -5.95$). El target vale 2.15 con probabilidad 0.9 y -6.355 con 0.1:

$$q_\varepsilon(s_{13}, \nearrow) = -1 + 0.9\,(0.9 \cdot 3.5 + 0.1 \cdot (-5.95)) = 1.2995 < q_*(s_{13}, \nearrow) = 2.15. \tag{4}$$

La media medida es 1.302, lo que confirma la predicción. Fases: hasta $\sim$500 pasos ambas Q son negativas (solo se han propagado los -1); entre 500 y 3 000 pasos $Q(s_{13}, \nearrow)$ sube a medida que s_{11} aprende; después oscila alrededor de 1.30. Cada punto de la curva es un valor instantáneo, no el esperado: una sola elección exploratoria en s_{11} lo baja en $\alpha(Q+6.355) \approx 0.77$, y la recuperación es geométrica.

3.3. Influencia de los hiperparámetros

	SARSA: $Q(s_{13}, \nearrow)$			QL	Retorno greedy		Política estable (ep.)	
α	σ teórica	σ emp.	media emp.	media	SARSA	QL	SARSA	QL
0.01	0.18	0.17	1.33	2.15	1.50	1.50	17 187	17 602
0.05	0.41	0.41	1.29	2.15	1.50	1.50	3 436	3 368
0.1	0.59	0.58	1.31	2.15	1.50	1.50	1 597	1 414
0.5	1.47	1.66	1.19	2.15	1.17	1.50	1/10 nunca	202
1.0	2.55	4.12	−3.17	2.15	−4.90	1.50	10/10 nunca	75

Tabla 2: Efecto de α (10 semillas). σ: desviación típica estacionaria de $Q(s_{13}, \nearrow)$. Política estable: episodio desde el que la acción greedy es óptima en los 17 estados alcanzables.

Tasa de aprendizaje. Entre visitas a $(s_{13}, \nearrow)$, las Q de s_{11} ya son constantes, así que $Q_{n+1} = (1-\alpha)Q_n + \alpha X_n$ es un proceso AR(1) con X_n independientes de media q_ε y desviación $\sigma_X = \gamma\sqrt{0.1 \cdot 0.9}\,(3.5 + 5.95) = 2.55$. Su media estacionaria es q_ε para cualquier α y su varianza, $\alpha\sigma_X^2/(2-\alpha)$. La Tabla 2 lo confirma para $\alpha \le 0.1$ (σ teórica/empírica: 0.18/0.17, 0.41/0.41, 0.59/0.58) con medias entre 1.29 y 1.33: α no cambia *qué* estima SARSA, sino la velocidad y el ruido. Más velocidad cuesta más ruido: la política tarda 17 187 episodios en estabilizarse con $\alpha = 0.01$ y 1 597 con $\alpha = 0.1$.

Con $\alpha \ge 0.5$ la aproximación falla porque el ruido realimenta la política. En la semilla 0 con $\alpha = 0.5$ (Figura 3, segmento plano), dos exploraciones seguidas en s_{11} hunden $Q(s_{13}, \nearrow)$ por debajo de $Q(s_{13}, \searrow)$ en el episodio 1 444. El error se propaga aguas arriba: en s_9, s_4 y s_{12} chocar

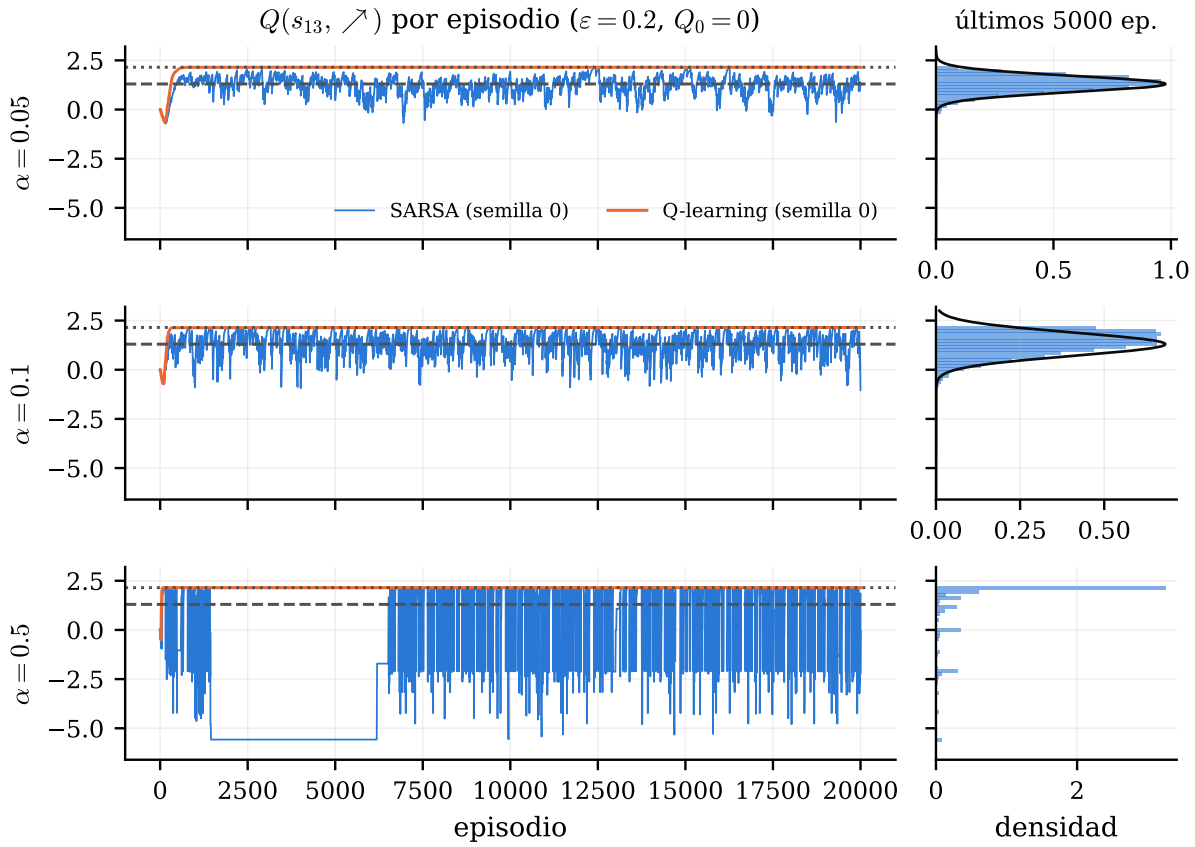


Figura 3: $Q(s_{13}, \nearrow)$ de SARSA y Q-learning para tres valores de α. Derecha: distribución en los últimos 5 000 episodios (10 semillas) y normal teórica $\mathcal{N}(q_\varepsilon, \sigma^2)$ para $\alpha \leq 0.1$. Líneas: q_* (puntos) y q_ε (trazos).

(-5) pasa a parecer mejor que continuar (≈ -5.5). s_{13} apenas vuelve a visitarse y el error persiste unos 4 800 episodios. El 11 % de las evaluaciones posteriores al episodio 1 000 son subóptimas. Con $\alpha = 1$, Q es la última muestra: el choque tiene valor determinista -5 y continuar vale lo que dio la última muestra, a menudo contaminada por un error exploratorio aguas abajo. La política greedy acaba chocando desde los cuatro estados iniciales (retorno -4.90).

Número de episodios. Con α y ε constantes, entrenar N episodios es exactamente el prefijo de un entrenamiento más largo con la misma semilla (comprobado). El presupuesto no cambia la dinámica, solo dónde se detiene. Con 500 episodios ($\approx 2\,000$ pasos) $Q(s_6, \searrow)$ está prácticamente aprendida (mediana: 1 873 pasos) y $Q(s_{13}, \nearrow)$ ronda q_ε. Con 2 000, la política es óptima en los 17 estados (mediana: episodio 1 509). Más allá de $\sim 10\,000$, Q ya no mejora: solo queda ruido estacionario. *La política se estabiliza mucho antes que los valores*, y estos nunca se detienen.

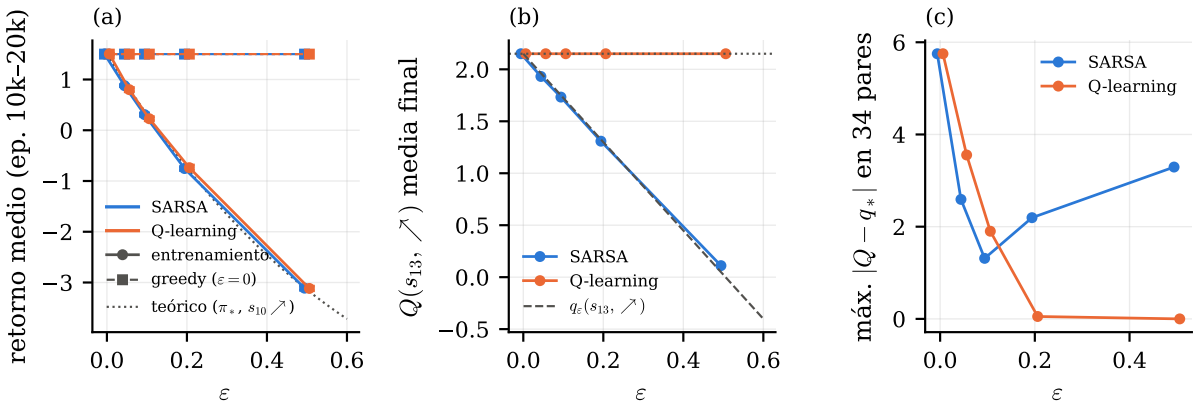


Figura 4: Efecto de ε (10 semillas, $\alpha = 0.1$, $Q_0 = 0$). (a) Retorno de entrenamiento y greedy, con la predicción exacta para la política ε-greedy de π_*. (b) Media final de $Q(s_{13}, \nearrow)$ y curva $q_\varepsilon(s_{13}, \nearrow)$. (c) Error máximo frente a q_* en los pares alcanzables.

Exploración. ε sí cambia el objetivo: $q_\varepsilon(s_{13}, \nearrow) = -1 + 0.9\,[(1 - \frac{\varepsilon}{2})3.5 - \frac{\varepsilon}{2}5.95]$ es lineal en ε, y las medias empíricas siguen esa recta (Figura 4b). Más exploración aumenta el impacto de las decisiones arriesgadas: la tasa de éxito en entrenamiento cae del 92.6 % ($\varepsilon = 0.05$) al 72.8 % (0.2) y al 42.5 % (0.5). El retorno coincide con el valor exacto de la conducta ε-greedy (Figura 4a). La política greedy es óptima en todos los casos, por lo que la pérdida se debe a explorar, no a aprender mal.

Inicialización. $Q_0 = 0$ es optimista para 19 de los 34 pares alcanzables ($q_* < 0$): una acción que acaba mal baja de 0 y la alternativa no probada pasa a ser greedy. Esto es exploración dirigida. Con $Q_0 = -5$ (pesimista), chocar tiene target $-5 = Q_0$ y no cambia nada, mientras que dar un paso tiene target $-1 + 0.9(-5) = -5.5 < -5$. El agente prefiere chocar hasta que la exploración descubre el objetivo y el valor se propaga: la evaluación greedy tarda 5 790 episodios en ser óptima (80 con $Q_0 = 0$; Figura 5a). $Q_0 = +5$ aprende igual de rápido y prueba más al principio (retorno -1.58 frente a -1.43 en 500 episodios). Además, los pares con $q_* = 5$ ($s_6\searrow$, s_7, $s_{14}\nearrow$) empiezan ya en su valor exacto. Tras suficientes visitas, Q_0 solo deja huella en los pares poco visitados, con un factor $(1 - \alpha)^N$.

Interacciones. La combinación peligrosa es poca exploración con pesimismo: con $\varepsilon = 0$ y $Q_0 = -5$ el agente choca en todos los episodios, y con $\varepsilon = 0.05$ el éxito es del 0.06 % tras 20 000 episodios (Figura 5b; SARSA se comporta igual), porque propagar el valor hasta s_{init} exige varias exploraciones consecutivas. El optimismo puede sustituir a la exploración: con $\varepsilon = 0$ y $Q_0 = +5$ la política es óptima en 130 episodios. Con α y ε altos (0.5/0.5), SARSA acumula ambos ruidos: retorno greedy final 0.38 frente a 1.50 con $\alpha = 0.05$.

Extensión GLIE. Con $\varepsilon_k = 0.2/(1 + k/1000)$, que acaba en 0.0095, $Q(s_{13}, \nearrow)$ alcanza 2.10 ± 0.15, muy cerca de $q_* = 2.15$, como predice la teoría.

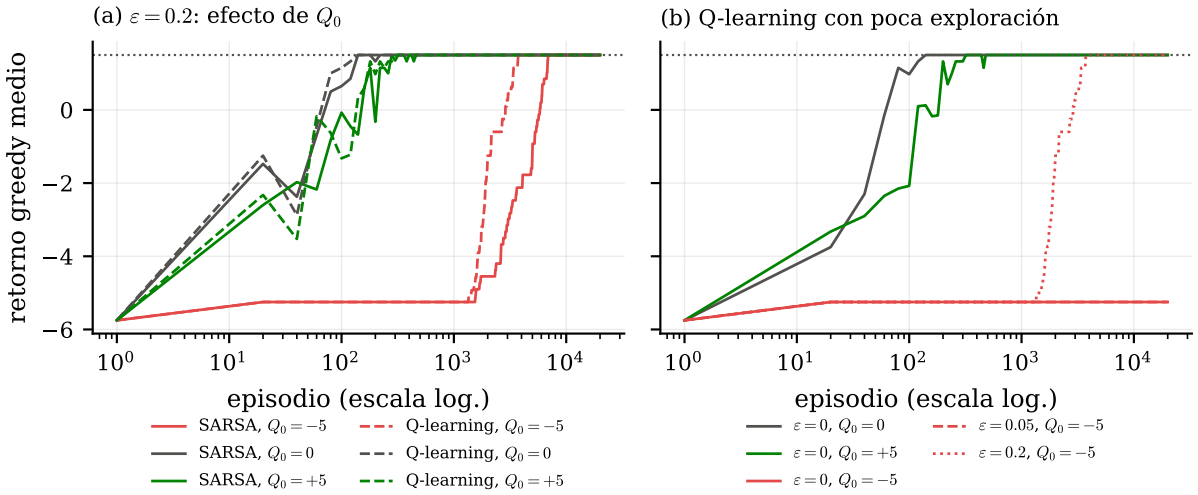


Figura 5: Retorno greedy medio desde s_{init} (10 semillas). (a) Efecto de Q_0 con $\varepsilon = 0.2$. (b) Q-learning con poca exploración (con $\varepsilon = 0$ SARSA es idéntico).

4. Q-learning

4.1. Fundamentos

Q-learning actualiza con el máximo del estado siguiente:

$$Q(S, A) \leftarrow Q(S, A) + \alpha\big[R + \gamma \max_{a'} Q(S', a') - Q(S, A)\big]. \tag{5}$$

Es *off-policy*: la conducta es ε-greedy, pero el target evalúa la política greedy, la acción que se ejecute después no interviene. Su valor esperado es la ecuación de optimalidad (1) (T_0, una contracción con punto fijo q_*). Converge a q_* con probabilidad 1 si todos los pares se visitan infinitas veces y α cumple Robbins–Monro [2]. En un entorno determinista el target no tiene ruido. Con α constante, una vez exactos los sucesores, $|Q_{n+1} - q_*| = (1 - \alpha)|Q_n - q_*|$: converge sin fluctuaciones, pero solo en los pares visitados.

4.2. Convergencia en s_6 y s_{13}

En s_6 (Figura 2, derecha) Q-learning y SARSA tienen el mismo target, porque no hay bifurcación aguas abajo. Por visita aprenden igual ($Q(s_6, \searrow)$ entra en la banda tras 38 visitas). Sin embargo, en pasos tardan el doble (3 759 frente a 1 873 en $\searrow$; 38 939 frente a 10 372 en $\nearrow$), porque durante los primeros 10 000 episodios su conducta pasa sobre todo por s_{14} y no por s_6 (Sección 5).

En s_{13} el target de $\nearrow$ usa $\max_a Q(s_{11}, a) = 3.5$, aunque después la conducta explore $\searrow$ en s_{11}. Por eso $Q(s_{13}, \nearrow) \to 2.15$ con desviación final $2 \cdot 10^{-13}$, frente a 0.58 en SARSA, y $Q(s_{13}, \searrow) \to -5.5$. Las fases son las mismas que en SARSA (valores negativos, propagación, final), pero el final es un punto fijo exacto.

La Figura 6a muestra que el error de cada par sigue $(1 - \alpha)^N$ hasta la precisión de máquina (10^{-16}). Los puntos desplazados a la derecha son pares cuyos sucesores convergieron más tarde. Esto explica los errores residuales: $Q(s_3, \nearrow)$, con 37 visitas en la semilla 0, vale 3.42 (error $0.08 \approx 3.5 \cdot 0.9^{37}$). En SARSA (Figura 6b), los pares con target determinista siguen la misma curva, pero los que tienen una bifurcación aguas abajo se estancan en un suelo de ruido entre 10^{-2} y 1.

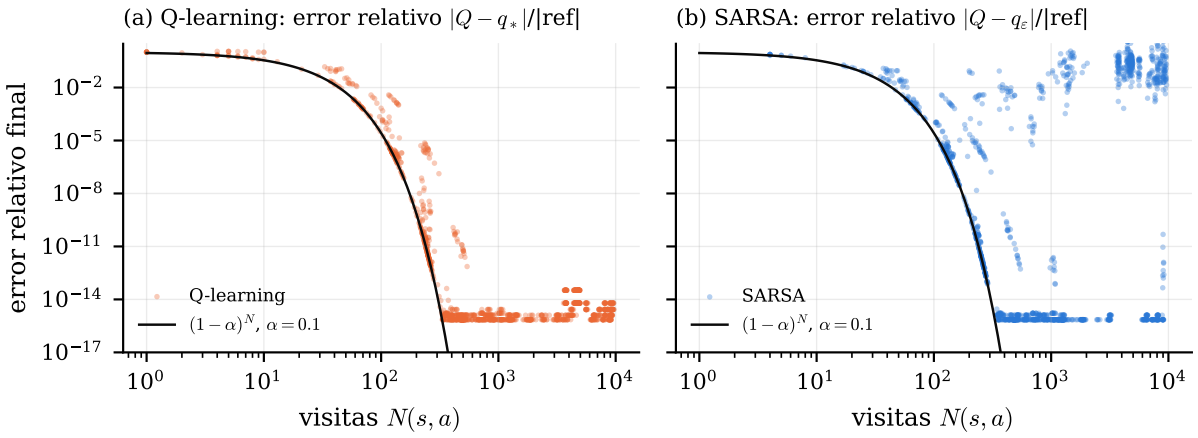


Figura 6: Error relativo final frente a visitas, para todos los pares alcanzables ($\alpha = 0.1$, $\varepsilon \in \{0.05, 0.1, 0.2, 0.5\}$, 10 semillas). Referencia: q_* para Q-learning, q_ε para SARSA.

4.3. Influencia de los hiperparámetros

α. Sin ruido en el target, un α mayor solo acelera: la política es óptima en los 17 estados tras 1 414 episodios con $\alpha = 0.1$, 202 con 0.5 y 75 con $\alpha = 1$ (Tabla 2). Con $\alpha = 1$ cada actualización es un *backup* de Bellman exacto, como una Value Iteration asíncrona sobre la experiencia. Es el comportamiento opuesto al de SARSA.

ε. No cambia el objetivo ($Q(s_{13}, \nearrow) = 2.15$ para todo ε, Figura 4b), pero sí la *cobertura*. Las acciones no greedy solo se aprenden explorando. Con $\varepsilon = 0.05$, $Q(s_6, \nearrow) = 0.08$ tras 20 000 episodios (frente a 2.15) y el error máximo es 3.56; con $\varepsilon = 0.5$ es $5 \cdot 10^{-11}$ (Figura 4c). El coste de explorar recae en el retorno de entrenamiento, igual que en SARSA.

Q_0 y $\varepsilon = 0$. $Q_0 = -5$ retrasa el aprendizaje (2 840 episodios hasta la política greedy óptima, Figura 5a) y $Q_0 = +5$ da el menor error final (0.001). Con $\varepsilon = 0$ y $Q_0 = +5$ el retorno greedy es óptimo, pero 3 pares no se visitan nunca y algunos estados fuera de la trayectoria conservan una acción incorrecta (error máximo 10.5). Una política óptima *sobre su trayectoria* no implica valores ni acciones correctos en todos los estados.

5. Comparación entre SARSA y Q-learning

Respuestas a las preguntas del enunciado, que justificamos a continuación con los cuatro criterios. *¿Misma política?* Sí: ambas son óptimas y solo pueden diferir en el empate de s_{10}. *¿Mismos valores?* No: Q-learning converge a q_* y SARSA a q_ε. *¿Mejor retorno en entrenamiento?* SARSA, en la fase intermedia (500–10 000 episodios), porque evita la ruta en la que explorar es más caro. En evaluación greedy ambos son idénticos.

	Retorno medio					greedy(s_{10}) =↘	
Episodios	SARSA	QL	Dif. [IC 95 %]	p	SARSA mejor	SARSA	QL
[0, 100)	−2.78	−2.59	−0.19 [−0.31, −0.07]	0.008	5/20	61 %	65 %
[100, 500)	−1.05	−0.99	−0.06 [−0.15, 0.02]	0.157	6/20	60 %	70 %
[500, 10 000)	−0.76	−0.94	0.18 [0.12, 0.24]	< 0.001	15/20	6 %	67 %
[10 000, 20 000)	−0.76	−0.75	−0.02 [−0.04, 0.00]	0.130	7/20	4 %	1 %

Tabla 3: Retorno de entrenamiento por fases (20 semillas pareadas). Dif.: SARSA − QL con IC bootstrap al 95 %; p: test de permutación de signos.

A. Eficiencia muestral. Con $\alpha \leq 0.1$ no hay diferencias relevantes (Figura 8). Ambos alcanzan el retorno greedy óptimo desde s_{init} hacia el episodio 80 ($\approx$ 300–450 pasos) y la acción

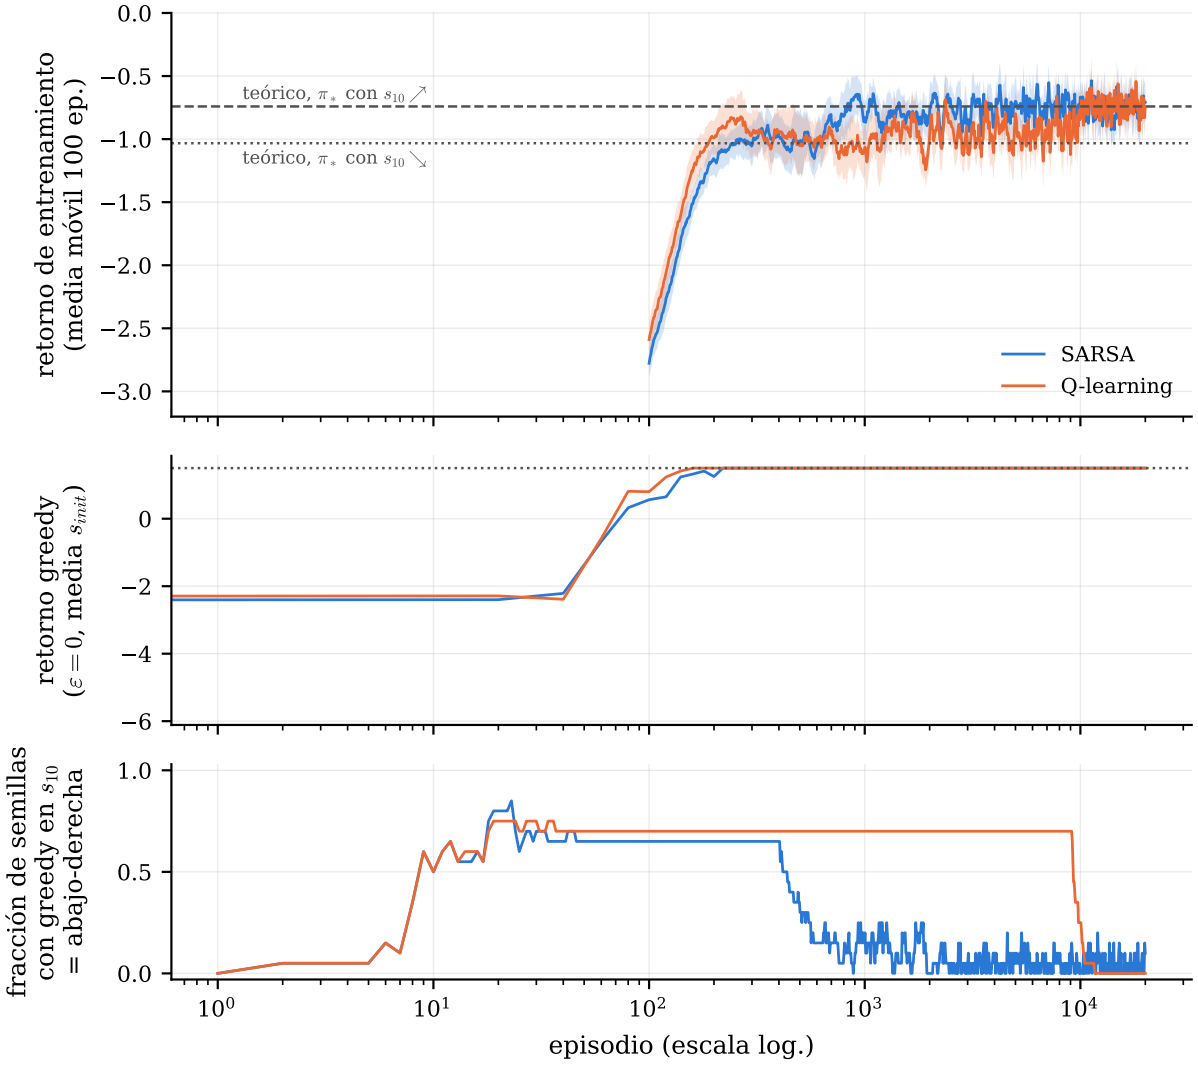


Figura 7: Configuración basal, 20 semillas. Arriba: retorno de entrenamiento (media móvil de 100 episodios, IC 95 %) y valor exacto de la conducta ε-greedy de π_* según la ruta elegida en s_{10}. Centro: retorno greedy. Abajo: fracción de semillas cuya acción greedy en s_{10} es ↘.

óptima en los 17 estados hacia el 1 500. La diferencia aparece con α: Q-learning mejora de forma monótona hasta $\alpha = 1$, porque su target es determinista, y SARSA empeora desde $\alpha = 0.5$, porque el suyo es ruidoso. Para un mismo par con target determinista ambos necesitan las mismas visitas. Las diferencias en pasos se deben a cuántas veces visita cada conducta ese par (caso de s_6). En ambos, la política se estabiliza mucho antes que los valores.

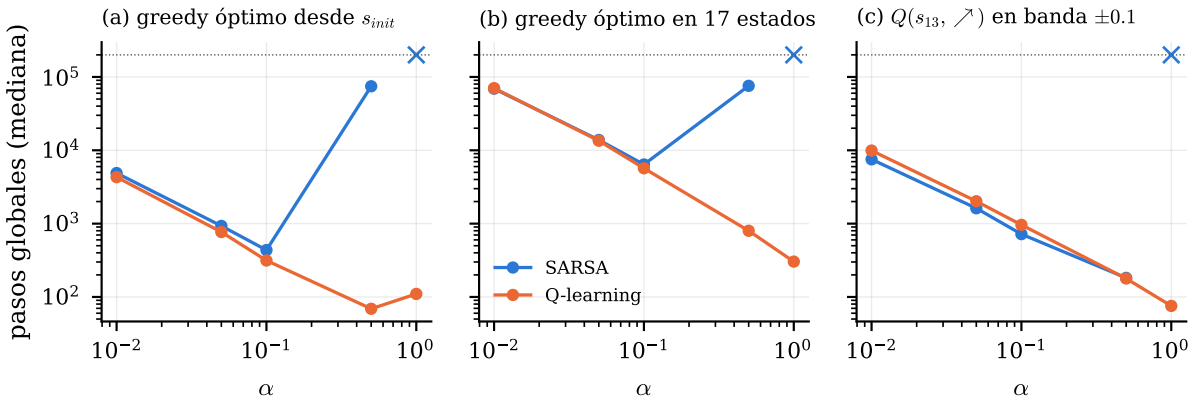


Figura 8: Pasos globales (mediana de 10 semillas) hasta que, de forma estable, (a) la política greedy es óptima desde s_{init} y (b) en los 17 estados alcanzables, y (c) hasta que $Q(s_{13}, \nearrow)$ entra por primera vez en ±0.1 de su referencia. ×: la mayoría de semillas no lo alcanza.

B. Evolución del retorno (Figura 7, Tabla 3). La evaluación greedy es idéntica: 1.5 en ambos, el óptimo. En entrenamiento distinguimos tres fases.

- *Inicial (0–100 episodios).* Ambos chocan con frecuencia (retorno ≈ -2.7). Q-learning es algo mejor (-0.19, $p = 0.008$), lo que es coherente con que el máximo propaga antes el valor del objetivo. La ventaja de su política greedy entre los episodios 20 y 200 no es significativa ($p = 0.08$).
- *Intermedia (500–10 000).* SARSA obtiene 0.18 más por episodio (IC $[0.12, 0.24]$, $p < 0.001$, 15 de 20 semillas). La causa es s_{10}: la acción greedy de Q-learning es $\searrow$ en el 67 % de los casos, la de SARSA en el 6 %. Explorando en s_{14} se pierden 11 puntos (choque en lugar de +5), y en s_6 solo 2. El valor exacto de la conducta ε-greedy es -0.741 por s_6 frente a -1.033 por s_{14}, y $0.67 \times 0.29 \approx 0.20$ coincide con lo medido. SARSA *ve* este riesgo, $q_\varepsilon(s_{10}, \nearrow) = 3.24 > q_\varepsilon(s_{10}, \searrow) = 2.56$; para Q-learning ambas valen 3.5.
- *Final (10 000–20 000).* La diferencia desaparece ($p = 0.13$), pero no porque Q-learning aprenda el riesgo.

¿Por qué Q-learning elige s_{14} y por qué deja de hacerlo? Con $Q_0 = 0$, `argmax` desempata hacia $\nearrow$. En s_{14}, $\nearrow$ es la acción que llega al objetivo y $Q(s_{14}, \nearrow)$ aprende el +5 enseguida; en s_6, $\nearrow$ es el rodeo. Al principio $\max Q(s_{14}) > \max Q(s_6)$, así que $\searrow$ domina en s_{10}. Al recibir más actualizaciones, queda más cerca de 3.5 por debajo y se mantiene greedy. Es una preferencia que se autorrefuerza. Hacia el episodio 9 300, tras unas 390 visitas, la acción no greedy alcanza *exactamente* 3.5 en doble precisión ($3.5 \cdot 0.9^n$ es menor que medio ulp para $n \approx 354$), y `argmax` resuelve el empate exacto hacia $\nearrow$. Es un artefacto numérico, no aprendizaje. Con $\varepsilon = 0.05$ ese empate no llega en 20 000 episodios y la ventaja de SARSA persiste hasta el final ($+0.08$, $p = 0.004$; predicción 0.9×0.10).

C. Exploración frente a explotación. SARSA incorpora en sus valores su propia exploración futura: estima la conducta que realmente ejecuta y prefiere rutas robustas a los errores. Q-learning aprende sobre la política greedy objetivo, ignora que la conducta explora y por eso alcanza q_* incluso con $\varepsilon = 0.5$, pero no distingue rutas igual de buenas sin exploración y distintas con ella. Las políticas difieren solo donde los $\arg\max$ de q_ε y q_* difieren. Lo comprobamos para

$\varepsilon \leq 0.5$ y r_{obs} hasta -50: solo ocurre en s_{10}, que es un empate en q_*, así que ambas políticas finales son óptimas. Explorar demasiado poco puede bloquear el aprendizaje ($\varepsilon = 0$, $Q_0 = -5$); explorar demasiado hunde el retorno de entrenamiento (-3.1 con $\varepsilon = 0.5$) y aleja a SARSA de q_*, aunque mejora la cobertura de Q-learning.

D. Valores finales (Tabla 4).

- *Q-learning:* los 34 pares alcanzables convergen a q_*. El error máximo es ≤ 0.08 y siempre aparece en pares con menos de 100 visitas (s_3 en 16 de 20 semillas).
- *SARSA:* converge a q_ε (por ejemplo, -1.815 frente a -1.815 en $s_4\searrow$; 1.30 en $s_{13}\nearrow$). Difiere de q_* siempre que aguas abajo haya una bifurcación con consecuencias asimétricas: $s_0\searrow$ 0.05 frente a 0.94, $s_4\searrow$ -1.81 frente a -0.16. Los pares cuya trayectoria posterior es determinista (s_6, s_{11}, s_{14}, s_{18}, última columna) coinciden en ambos.
- *Inalcanzables:* s_2, s_{16} y s_{17} conservan Q_0 en los dos algoritmos. Es falta de experiencia, no un error de estimación.

	$a=\nearrow$					$a=\searrow$				
s	q_*	q_ε	SARSA (σ)	QL	N S/QL	q_*	q_ε	SARSA (σ)	QL	N S/QL
s_0	−5.00	−5.00	−5.00 (0.00)	−5.00	498/504	0.94	0.05	0.05 (0.42)	0.94	4498/4501
s_1	−5.00	−5.00	−5.00 (0.00)	−5.00	255/253	−5.00	−5.00	−5.00 (0.00)	−5.00	254/252
s_3	3.50	3.50	3.49 (0.01)	3.42	74/60	3.50	3.50	3.50 (0.00)	3.46	613/360
s_4	−5.50	−5.50	−5.50 (0.00)	−5.50	510/505	−0.16	−1.81	−1.81 (0.40)	−0.16	4496/4481
s_5	−5.00	−5.00	−5.00 (0.00)	−5.00	902/910	2.15	1.86	1.83 (0.13)	2.15	8063/8074
s_6	2.15	2.15	2.15 (0.00)	2.15	693/436	5.00	5.00	5.00 (0.00)	5.00	6159/3876
s_7	5.00	5.00	5.00 (0.00)	5.00	6520/6274	5.00	5.00	5.00 (0.00)	5.00	725/702
s_8	0.94	0.05	0.02 (0.43)	0.94	4476/4491	−5.00	−5.00	−5.00 (0.00)	−5.00	506/501
s_9	−5.00	−5.00	−5.00 (0.00)	−5.00	899/904	0.94	−0.45	−0.44 (0.53)	0.94	8109/8099
s_{10}	3.50	3.24	3.23 (0.19)	3.50	6854/4319	3.50	2.56	2.32 (0.56)	3.50	1240/3763
s_{11}	3.50	3.50	3.50 (0.00)	3.50	6544/6554	−5.95	−5.95	−5.95 (0.00)	−5.95	728/727
s_{12}	−0.16	−1.81	−1.81 (0.39)	−0.16	4532/4529	−5.00	−5.00	−5.00 (0.00)	−5.00	508/504
s_{13}	2.15	1.30	1.30 (0.58)	2.15	7267/7286	−5.50	−5.59	−5.58 (0.06)	−5.50	818/818
s_{14}	5.00	5.00	5.00 (0.00)	5.00	1117/3369	−5.50	−5.50	−5.50 (0.00)	−5.50	122/384
s_{15}	−5.50	−5.50	−5.50 (0.00)	−5.50	475/488	−5.50	−5.50	−5.50 (0.00)	−5.50	359/355
s_{18}	−5.95	−5.95	−5.95 (0.00)	−5.95	110/111	−5.00	−5.00	−5.00 (0.00)	−5.00	701/707
s_{19}	−5.00	−5.00	−5.00 (0.00)	−5.00	595/839	−5.00	−5.00	−5.00 (0.00)	−5.00	356/379

Tabla 4: Valores finales (media temporal del último 25 %, 20 semillas; entre paréntesis, desviación típica temporal de SARSA) y visitas medianas N (SARSA/QL). Estados inalcanzables omitidos: $Q = Q_0 = 0$ y $N = 0$ en ambos.

En cuanto a las políticas, las finales son óptimas en todos los estados alcanzables y coinciden salvo en s_{10} en 2 de 20 semillas. En ellas SARSA acaba en $\searrow$, igualmente óptima, porque $Q(s_{10}, \searrow)$ fluctúa; Q-learning elige $\nearrow$ en 20/20 por el desempate exacto. Las acciones de s_1, s_{15} y s_{19} siguen alternando hasta el final sin consecuencias, porque ambas son equivalentes.

6. Conclusiones

- **Cada algoritmo estima una cosa distinta.** Q-learning muestrea la ecuación de optimalidad y converge a q_*, exactamente en este entorno determinista. SARSA muestrea T_ε y fluctúa alrededor de q_ε. Ejemplo: $Q(s_{13}, \nearrow)$ vale 1.30 en SARSA frente a $q_* = 2.15$, y la diferencia es exactamente el coste esperado de explorar en s_{11}.
- **La política se estabiliza antes que los valores** (unos 1 500 episodios frente a unos 10 000 de Q-learning, mientras que SARSA nunca se detiene). Los pares no greedy y los inalcanzables muestran que convergencia exige visitas: el error decae como $(1-\alpha)^N$.
- **α actúa de forma opuesta en cada algoritmo.** En SARSA fija la varianza, $\alpha\sigma_X^2/(2-\alpha)$, y con $\alpha \geq 0.5$ el ruido colapsa la política. En Q-learning, sin ruido en el target, solo acelera.

- **SARSA obtiene mejor retorno de entrenamiento solo cuando las políticas difieren** en un estado donde explorar tiene costes asimétricos. Aquí es únicamente s_{10}, con una ventaja de 0.18 por episodio que el modelo predice. Su desaparición final es un artefacto de coma flotante, no aprendizaje.
- **Exploración e inicialización interactúan.** $Q_0 = 0$ ya es optimista en este entorno; el pesimismo con poca exploración ($Q_0 = -5$, $\varepsilon \leq 0.05$) atrapa al agente en chocar para siempre.

Limitaciones. Un único entorno determinista y pequeño (no aparece el sesgo de maximización de Q-learning, que requiere targets ruidosos), 10–20 semillas por configuración y α, ε constantes salvo en la extensión GLIE.

Uso de la IA

Hemos utilizado un asistente de IA (Claude) para revisar la implementación, automatizar barridos y gráficas y mejorar la redacción y el formato LaTeX. Todas las cifras proceden de nuestros scripts (`lab2/experiments`), que las reproducen con las semillas indicadas, y hemos verificado cada afirmación contra los datos.

Referencias

[1] R. S. Sutton y A. G. Barto, *Reinforcement Learning: An Introduction*, 2.ª ed., MIT Press, 2018 (cap. 6). [2] C. Watkins y P. Dayan, Q-learning, *Machine Learning* 8, 1992. [3] S. Singh et al., Convergence results for single-step on-policy RL algorithms, *Machine Learning* 38, 2000.